

TRÄNING AV ROBUSTA MODELLER MED REDUCERAD ORDNING MED HJÄLP AV ADJOINTMETODEN

FRANCISCO GARCÍA ATIENZA

Examensarbete
2025:E20



LUNDS UNIVERSITET

Naturvetenskaplig fakultet
Matematikcentrum
Numerisk analys

TRÄNING AV ROBUSTA MODELLER MED REDUCERAD ORDNING MED HJÄLP AV ADJOINTMETODEN

FRANCISCO GARCÍA ATIENZA

Examensarbete
2025:E20



LUNDS UNIVERSITET

Naturvetenskaplig fakultet
Matematikcentrum
Numerisk analys

TACK

Jag vill rikta min djupa tacksamhet till mina klasskamrater och professorer under de gångna fem åren av kandidat- och masterstudier, utan någon särskild ordning: Claus, Philipp, Robert, Tony, Erik, Anna-Maria, Viktor, Kjell, Anitha, Jan-Fredrik och många andra. Av var och en av er har jag lärt mig något unikt, och ni har alla bidragit till att fördjupa min passion för matematik.

Ett särskilt tack går till min handledare, Mengwu Guo, för hans tillgänglighet, hans ovärderliga vägledning och för att han introducerat mig till den genuint fascinerande världen av vetenskaplig maskininlärning (*Scientific Machine Learning*).

Sist men absolut inte minst tillägnar jag detta examensarbete till min familj. Till mina sex syskon, som jag älskar av hela mitt hjärta; till min far, som alltid lever i mitt minne och som lärde mig värdet av ödmjukhet inför bildning; till min mor, för att hon dagligen visar mig vad det innebär att offra sig för det man älskar mest; och till min livskamrat under denna resa, Alfredo, för hans villkorslösa kärlek i både med- och motgång. Ert stöd har varit min största styrka.

Lund, juni 2025

Francisco García Atienza

SAMMANFATTNING

Reducerade ordningsmodeller (Reduced-Order Models, ROM) har blivit oundgängliga verktyg för att minska den beräkningsmässiga komplexiteten i högtrogna simuleringar inom vetenskap och teknik. I detta examensarbete presenterar vi ett nytt ramverk för träning som kombinerar den integrala formuleringen av operatorinferens (Operator Inference, OpInf) med adjungerade tillståndsmetoder (*adjoint-state methods*) för att erhålla robusta och datadrivna ROM. Genom att formulera en förlustfunktional i kontinuerlig tid som integrerar de styrande ekvationerna över tid, undviker vårt tillvägagångssätt explicit derivering av brusiga tillståndsdata och regulariserar i sig självt inlärningsproblemet. Vi härleder de motsvarande adjungerade ekvationerna för exakt beräkning av förlustfunktionalens gradient och presenterar en gradientnedstigningsalgoritm som effektivt uppdaterar ROM-parametrarna.

Vi validerar den föreslagna metoden på två kanoniska icke-linjära partiella differentialekvationer (PDE): den viskösa Burgers ekvation och den tvådimensionella Fisher-KPP-reaktions-diffusionsekvationen. Genom systematiska numeriska experiment jämför vi den ROM som tränats med den adjungerade metoden med standardmetoden för OpInf under två scenarier: (i) olika densiteter av temporala ögonblicksbilder (snapshots) och (ii) närvaro av additivt gaussiskt brus. Våra resultat visar att båda metoderna uppvisar jämförbar prestanda när ögonblicksbilderna undersamlas likformigt; den adjungerade metoden uppvisar dock högre noggrannhet och stabilitet i närvaro av brusiga data. Dessutom, även om varje träningsiteration kräver en bakåtgående beräkning (*backward pass*), skalar den totala beräkningskostnaden konstant med avseende på antalet parametrar, vilket gör metoden till ett särskilt attraktivt alternativ för fullständiga modeller av mycket hög dimension.

ABSTRACT

Reduced-order models (ROMs) have become indispensable tools for reducing the computational complexity of high-fidelity simulations in science and engineering. In this thesis, we introduce a novel training framework that combines the integral form of Operator Inference (OpInf) with adjoint-state methods to yield robust, data-driven ROMs. By formulating a continuous-time loss functional that integrates the governing equations over time, our approach avoids explicit differentiation of noisy state data and inherently regularizes the learning problem. We derive the corresponding adjoint equations for exact gradient computation of the loss functional and present a gradient-descent minimization algorithm that updates ROM parameters efficiently.

We validate the proposed method on two canonical nonlinear PDEs: the viscous Burgers' equation and the two-dimensional Fisher-KPP reaction-diffusion equation. In systematic numerical experiments, we compare the adjoint-trained ROM against the standard OpInf approach under (i) varying snapshot density and (ii) additive Gaussian noise. Our results show that both methods perform comparably when snapshots are uniformly sub-sampled, but the adjoint method exhibits improved accuracy and stability in the presence of noisy data. Moreover, although each training iteration requires a backward pass, the overall computational cost scales constantly with the number of parameters, making the method favorable for very high-dimensional full models.

INNEHÅLL

<i>Figurer</i>	ix
1 Introduktion	1
2 Preliminaries	5
2.1 Modellordningsreducering (MOR)	5
2.2 Operatorinferens (OpInf)	8
3 Adjunktmetod för inferens av operatorer	13
3.1 En förlustfunktional i kontinuerlig tid	13
3.2 Ekvationerna för det adjunkta tillståndet	15
3.3 Ekvationer för de tre gradienterna	24
3.3.1 $\nabla_{\hat{\mathbf{q}}} \hat{\mathbf{f}}$	24
3.3.2 $\nabla_{\hat{\mathbf{q}}} g$	25
3.3.3 $\nabla_{\hat{\theta}} \hat{\mathbf{f}}$	26
3.4 Gradientgradientmetod för parameteroptimering	27
3.5 Algoritmen för adjunktmetoden	31
4 Numeriska experiment	33
4.1 Viskös Burgers ekvation	34
4.2 Fisher-KPP-ekvationen	42
5 Diskussion	47

6	Slutsatser	51
	<i>Referenser</i>	53
	Bilagor	
A	Ytterligare teoretiska grunder	57
A.1	Matrisering av tensorer	57
A.2	Kubisk splineinterpolation	59
B	Python-kod	61

FIGURER

3.1	Schema över processen för inferens av reducerade ordningsmodeller (ROM); det klassiska algebraiska flödet för OpInf (övre grenen) och raffinering baserad på den dynamiska adjunktmetoden (nedre grenen).	32
4.1	Dynamik för den viskösa Burgers ekvation som används för datagenerering. . .	35
4.2	Resultat av reduceringen av datadensitet för det syntetiska experimentet med Burgers ekvation.	36
4.3	Prediktionsfel mot tid för varje körning av datadensitetsreducering i experi- mentet med Burgers ekvation.	37
4.4	Relativt fel mot r för varje körning av datadensitetsreducering i experimentet med Burgers ekvation.	38
4.5	Simuleringar av brusstörningar för det syntetiska experimentet med Burgers ekvation.	39
4.6	Prediktionsfel mot tid för varje körning av brusnivå i experimentet med Burgers ekvation.	40
4.7	Relativt fel mot r för varje körning av brusstörning i experimentet med Burgers ekvation.	41
4.8	Dynamik för FKPP-ekvationen som används för datagenerering.	43
4.9	Simuleringar av brusstörningar för det syntetiska experimentet med FKPP- ekvationen.	44
4.10	Prediktionsfel mot tid för varje körning av brusnivå i experimentet med FKPP- ekvationen.	45
4.11	Relativt fel mot r för varje körning av brusstörning i experimentet med FKPP- ekvationen.	46

INTRODUKTION

Reducerad ordningsmodellering ligger i skärningspunkten mellan numerisk analys och datadriven beräkningsvetenskap, och erbjuder kraftfulla tekniker för att minska komplexiteten i dynamiska system. Detta examensarbete utvecklar ett nytt ramverk för träning av robusta reducerade ordningsmodeller (ROM) genom att integrera operatorinferens (*Operator Inference*, OpInf) med den adjungerade tillståndsmetoden. Genom att överbrygga klyftan mellan klassiska numeriska tekniker och moderna maskininlärningsparadigm presenterar vi ett ramverk som förbättrar stabiliteten och brusrobustheten hos datadrivna ROM, vilket är avgörande krav för tillämpningar inom beräkningsfysik och ingenjörsvetenskap.

Historisk bakgrund

Reducerad ordningsmodellering (ROM) har en lång historia inom numerisk analys och beräkningsfysik, där den växte fram som en metod för att förenkla komplexa dynamiska system med bibehållande av deras väsentliga egenskaper. De tidigaste projektionsbaserade modellreduceringsteknikerna kan spåras tillbaka till balanserad trunkering och modifierad ortogonalnedbrytning (POD), vilka tillämpades i stor utsträckning inom reglerteknik och strömningsmekanik [1, 2]. Idén om att lära sig reducerade ordningsmodeller direkt från data fick dock stor betydelse under 2000-talet, i synnerhet med framväxten av datadrivna tekniker och nya maskininlärningsmetoder.

En anmärkningsvärd utveckling i denna riktning är operatorinferens (OpInf), en metod som introducerades för att approximera reducerade operatorer direkt från tidsseriedata utan att kräva tillgång till det fullständiga systemets ekvationer. Detta tillvägagångssätt har formaliserats som en icke-intrusiv projektionsbaserad modellreduceringsteknik, vilket möjliggör effektiv inläring av lågdimensionella modeller från högtrognasimuleringar [3]. I ett bredare perspektiv har integrationen av inversa problem och modellreducering utforskats, vilket visar hur fysikbaserade modeller kan infereras från data med

bibehållen tolkningsbarhet och fysikalisk konsistens [4].

Under de senaste åren har skärningspunkten mellan maskininlärning och beräkningsmodellering gett upphov till nya ramverk såsom neurala ordinära differentialekvationer (*Neural ODEs*) [5]. Dessa modeller erbjuder ett flexibelt sätt att lära sig tidskontinuerlig dynamik från data och har inspirerat till nya formuleringar för att lära sig reducerade representationer av dynamiska system. En avgörande aspekt för att träna sådana modeller effektivt är beräkningen av gradienter, vilket kan utföras med den adjungerade metoden – ett klassiskt tillvägagångssätt inom optimal styrning och optimering under bivillkor av partiella differentialekvationer (PDE) [6, 7].

Detta examensarbete bygger vidare på dessa framsteg genom att träna operatorinferens med hjälp av adjungerade metoder. Specifikt är målet att reformulera härledningen av det adjungerade problemet inom den integrala formen av OpInf. Genom att göra detta syftar detta arbete till att utveckla robusta reducerade ordningsmodeller som effektivt kan hantera ofullständiga data.

Studiens motivation

Den ökande komplexiteten hos beräkningsmodeller inom fysik och teknik kräver ROM som bibehåller noggrannheten samtidigt som de uppnår en betydande dimensionell reduktion. Traditionella OpInf-metoder är effektiva i scenarier med rena data, men möter fundamentala begränsningar vid hantering av verkliga mätdata som innehåller brus eller ofullständiga observationer, samt när den underliggande dynamiken uppvisar starka icke-linjäriteter eller komplexa beroenden som är svåra att representera med fördefinierade operatorformer. Denna utmaning motiverar vår omformulering av inlärningsproblemet genom en integralbaserad förlustfunktional kombinerad med optimering baserad på det adjungerade tillståndet.

Vårt tillvägagångssätt riktar sig specifikt mot kanoniska modellproblem inom beräkningsfysik, såsom den viskösa Burgers ekvation, som modellerar bildandet av stötvågor, och Fisher-KPP-ekvationen, som beskriver reaktions-diffusionstekniker, där brister i mätdata avsevärt kan försämra ROM-modellens prestanda. Till skillnad från konventionell OpInf, som löser linjära regressionsproblem genom att använda potentiellt brusiga derivataapproximationer, undviker vår metod explicit differensiering av tillstånden genom att omformulera problemet med hjälp av de styrande ekvationernas integrala form. Detta examensarbete undersöker om integrationen av den inlärd dynamiken över tid i sig självt kan dämpa mätbrus, och därmed fungera som ett slags inbyggt lågpassfilter som genererar stabilare och mer tillförlitliga reducerade ordningsmodeller.

Den centrala innovationen ligger i att kombinera denna integrala formulering med det adjungerade tillståndets metoder för effektiv gradientberäkning. Genom att härleda de adjungerade ekvationerna direkt för den integrala formen av OpInf möjliggör vi gradi-

entbaserad optimering av ROM-parametrarna med bibehållen numerisk stabilitet. Detta tillvägagångssätt erbjuder följande huvudsakliga fördelar:

- (i) Eliminering av numerisk derivering på potentiellt brusiga och glesa tillståndsdata,
- (ii) Inbyggd regularisering genom tidsintegration,
- (iii) Kompatibilitet med moderna differentieringsramverk (såsom *Neural ODEs*) som naturligt fångar komplexa och ickelinjära relationer i systemdynamiken,
- (iv) Beräkningsmässig effektivitet och fördelar gällande minneslagring, eftersom det eliminerar behovet av att lagra information för tillståndsderivator och, som kommer att visas senare, kostnaden för den adjungerade metoden är konstant med avseende på antalet modellparametrar.

Sammantaget leder dessa fördelar till betydligt robustare modeller, särskilt när man arbetar med imperfekt data från experimentella mätningar och simuleringar.

De huvudsakliga målen med detta arbete är att:

- Härleda och reformulera det adjungerade problemet inom ramen för den integrala formen av OpInf, och därmed etablera de teoretiska grunderna för gradientberäkning vid träning av integralbaserade ROM.
- Utveckla ROM-ramverk som bibehåller numerisk stabilitet under tidsintegration, samtidigt som de uppvisar robusthet mot olika databristfälligheter, inklusive additivt brus och gles mätdata.

Resten av detta examensarbete är organiserat enligt följande:

- Kapitel 2 introducerar operatorinferens, en icke-intrusiv och datadriven ROM som utgör grunden för inlärningsproceduren i det föreslagna tillvägagångssättet.
- Kapitel 3 presenterar en detaljerad härledning av ekvationerna för den adjungerade metoden som används för att minimera förlustfunktionalen i integralform inom OpInf-ramverket.
- Kapitel 4 redovisar de numeriska experimenten som validerar den föreslagna metoden.
- Kapitel 5 och 6 diskuterar konsekvenserna av resultaten, presenterar slutsatserna och skisserar möjliga framtida forskningslinjer.

PRELIMINARIER

I detta kapitel introduceras de grundläggande koncepten och de matematiska verktygen som ligger till grund för utvecklingen av de reducerade ordningsmodeller som presenteras i detta examensarbete. Vi börjar med en översikt av projektionsbaserade ROM [2] och belyser rollen för modifierad ortogonalnedbrytning (*Proper Orthogonal Decomposition*, POD) [8] som ett viktigt verktyg för att extrahera dominanta moder från högtrognas datasätt. Därefter undersöks de teoretiska grunderna för operatorinferens (*Operator Inference*, OpInf) [9].

2.1 Modellordningsreducering (MOR)

En av de främsta utmaningarna i många tillämpade matematiska problem, särskilt de som styrs av partiella differentialekvationer, ligger i att balansera beräkningsmässig genomförbarhet med en noggrann representation av de underliggande fysikaliska fenomenen. I många tillämpningar inom numerisk analys och beräkningsfysik är dimensionen n extremt stor, vilket gör direkta simuleringar beräkningsmässigt kostsamma eller till och med överkomliga. Målet med modellreducering är att konstruera en ersättningsmodell (eller *reducerad ordningsmodell* – ROM) som noggrant approximerar dynamiken i ett under- rum av betydligt lägre dimension genom projektionstekniker.

Betrakta en högtrogen *fullständig ordningsmodell* (FOM) som styrs av ett system av tidsberoende evolutionsekvationer:

$$\frac{d}{dt}\mathbf{q}(t) = \mathbf{f}(\mathbf{q}(t), \mathbf{u}(t)), \quad t \in [0, T], \quad (2.1)$$

där $\mathbf{q}(t) \in \mathbb{R}^n$ representerar tillståndsvektorn för ett komplext system vid tiden t , $\mathbf{u}(t) \in \mathbb{R}^m$ betecknar insignaler eller drivande termer, och funktionen $\mathbf{f} : \mathbb{R} \times \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}^n$ definierar den (potentiellt ickelinjära) dynamiken härledd från en rumslig diskretisering av de styrande ekvationerna (ofta PDE:er).

För att konkretisera idéerna kommer vi i detta examensarbete att fokusera på det

vanliga fall där den fullständiga dynamiken har en kvadratisk operatorstruktur. Med andra ord antar vi att högerledet i (2.1) kan uttryckas som

$$\dot{\mathbf{q}}(t) = \mathbf{f}(\mathbf{q}(t), \mathbf{u}(t)) = \mathbf{c} + \mathbf{A}\mathbf{q}(t) + \mathbf{H}[\mathbf{q}(t) \otimes \mathbf{q}(t)] + \mathbf{B}\mathbf{u}(t), \quad (2.2)$$

där $\mathbf{c} \in \mathbb{R}^n$ är en konstant vektor, $\mathbf{A} \in \mathbb{R}^{n \times n}$ och $\mathbf{B} \in \mathbb{R}^{n \times m}$ är linjära operatorer, och $\mathbf{H} \in \mathbb{R}^{n \times n^2}$ fångar de kvadratiske interaktionerna genom tensorprodukten $\mathbf{q}(t) \otimes \mathbf{q}(t)$ (se Bilaga A.1 - Matrixform av tensorer).

En ROM söker en noggrann approximation av FOM-lösningen genom att begränsa dynamiken till ett reducerat underrum:

$$\mathbf{q}(t) \approx \mathbf{V}_r \hat{\mathbf{q}}(t), \quad \mathbf{V}_r \in \mathbb{R}^{n \times r}, \quad \hat{\mathbf{q}} \in \mathbb{R}^r, \quad r \ll n, \quad (2.3)$$

där kolonnerna i $\mathbf{V}_r$ bildar en reducerad bas som spänner upp det lågdimensionella under-
rummet.

Ett vanligt tillvägagångssätt för att konstruera den reducerade basen är modifierad ortogonalnedbrytning (POD). Givet en samling av k ögonblicksbilder (*snapshots*) av lösningen till (2.1), det vill säga,

$$\left. \frac{d}{dt} \mathbf{q}(t) \right|_{t=t_i} = \mathbf{f}(\mathbf{q}(t_i), \mathbf{u}(t_i))$$

vid givna tidpunkter t_i för $i = 1, \dots, k$, definierar vi *tillståndsmatrisen för ögonblicksbilder* $\mathbf{Q}$ som

$$\mathbf{Q} = \begin{bmatrix} | & | & & | \\ \mathbf{q}(t_1) & \mathbf{q}(t_2) & \dots & \mathbf{q}(t_k) \\ | & | & & | \end{bmatrix}. \quad (2.4)$$

Därefter erhålls den (ortonormala) POD-basen $\mathbf{V}_r \in \mathbb{R}^{n \times r}$ genom att minimera rekonstruktionsfelet i L^2 -mening:

$$\begin{aligned} \mathbf{V}_r = \underset{\mathbf{W} \in \mathbb{R}^{n \times r}}{\operatorname{argmin}} \quad & \sum_{i=1}^k \|\mathbf{q}(t_i) - \mathbf{W}\mathbf{W}^\top \mathbf{q}(t_i)\|_2^2 \\ \text{s.t.} \quad & \mathbf{W}^\top \mathbf{W} = \mathbf{I} \quad (\text{Galerkinvillkor}). \end{aligned} \quad (2.5)$$

Denna formulering är ekvivalent med att beräkna en trunkerad singularvärdesuppdelning (SVD) av rang r för tillståndsmatrisen $\mathbf{Q}$,

$$\mathbf{Q} = \mathbf{\Phi} \mathbf{\Sigma} \mathbf{\Psi}^\top,$$

där POD-basvektorerna ges av de första r kolonnerna i $\mathbf{\Phi}$:

$$\mathbf{V}_r = \mathbf{\Phi}_{:,1:r}. \quad (2.6)$$

Valet av trunkeringsdimensionen r baseras vanligtvis på det relativa energinnehållet hos singularvärdena (ackumulerad energi, κ_r):

$$\kappa_r = \frac{\sum_{i=1}^r \sigma_i^2}{\sum_{i=1}^k \sigma_i^2} \geq 1 - \epsilon_{\text{POD}}, \quad (2.7)$$

där $\epsilon_{\text{POD}} > 0$ är en föreskriven tolerans och σ_i betecknar det i -te singularvärdet för $\mathbf{Q}$. Optimaliteten hos POD-basen karakteriseras av projektionsfelet:

$$\sum_{i=1}^k \|\mathbf{q}(t_i) - \mathbf{V}_r \mathbf{V}_r^T \mathbf{q}(t_i)\|_2^2 = \sum_{i=r+1}^k \sigma_i^2, \quad (2.8)$$

vilket minimeras bland alla ortonormala baser av rang r .

Projektionen av den fullständiga lösningen på underrummet som spänns upp av $\mathbf{V}_r$ ger en reducerad representation som fångar systemets mest energirika moder, vilket leder till vad som kallas det *reducerade dynamiska systemet*:

$$\dot{\hat{\mathbf{q}}}(t) = \mathbf{V}_r^T \mathbf{V}_r \dot{\mathbf{q}}(t) = \mathbf{V}_r^T \dot{\mathbf{q}}(t) = \mathbf{V}_r^T \mathbf{f}(\mathbf{V}_r \hat{\mathbf{q}}(t), \mathbf{u}(t)). \quad (2.9)$$

Betrakta det högdimensionella systemet i (2.2). Genom att expandera dynamiken i polynomform erhålls

$$\begin{aligned} \dot{\hat{\mathbf{q}}}(t) &= \mathbf{V}_r^T \mathbf{f}(\mathbf{V}_r \hat{\mathbf{q}}(t), \mathbf{u}(t)) \\ &= \mathbf{V}_r^T (\mathbf{c} + \mathbf{A} \mathbf{V}_r \hat{\mathbf{q}}(t) + \mathbf{H}[(\mathbf{V}_r \hat{\mathbf{q}}(t)) \otimes (\mathbf{V}_r \hat{\mathbf{q}}(t))] + \mathbf{B} \mathbf{u}(t)). \end{aligned}$$

Eftersom $\mathbf{V}_r^T \mathbf{V}_r = \mathbf{I}$ och genom att använda egenskapen $(\mathbf{X}\mathbf{Y}) \otimes (\mathbf{Z}\mathbf{W}) = (\mathbf{X} \otimes \mathbf{Z})(\mathbf{Y} \otimes \mathbf{W})$, kan uttrycket ovan förenklas till

$$\begin{aligned} \dot{\hat{\mathbf{q}}}(t) &= \mathbf{V}_r^T \mathbf{f}(t, \mathbf{V}_r \hat{\mathbf{q}}(t), \mathbf{u}(t)) = \hat{\mathbf{c}} + \hat{\mathbf{A}} \hat{\mathbf{q}}(t) + \hat{\mathbf{H}}[\hat{\mathbf{q}}(t) \otimes \hat{\mathbf{q}}(t)] + \hat{\mathbf{B}} \mathbf{u}(t), \\ &=: \hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \mathbf{u}(t); \hat{\boldsymbol{\theta}}) \end{aligned} \quad (2.10)$$

där de *reducerade ordningsoperatorerna* definieras som

$$\mathbb{R}^r \ni \hat{\mathbf{c}} = \mathbf{V}_r^T \mathbf{c}, \quad \mathbb{R}^{r \times r} \ni \hat{\mathbf{A}} = \mathbf{V}_r^T \mathbf{A} \mathbf{V}_r, \quad \mathbb{R}^{r \times r^2} \ni \hat{\mathbf{H}} = \mathbf{V}_r^T \mathbf{H}(\mathbf{V}_r \otimes \mathbf{V}_r^T), \quad \mathbb{R}^{r \times m} \ni \hat{\mathbf{B}} = \mathbf{V}_r^T \mathbf{B},$$

$\hat{\boldsymbol{\theta}} = [\hat{\mathbf{c}} \ \hat{\mathbf{A}} \ \hat{\mathbf{H}} \ \hat{\mathbf{B}}] \in \hat{\boldsymbol{\Theta}}$ betecknar parameteruppsättningen där $\hat{\boldsymbol{\Theta}} \in \mathbb{R}^{r \times (1+r+r^2+m)}$ representerar det tillåtna parameterrummet, och $\hat{\mathbf{f}}$ är högerledet i den reducerade modellen. Sålunda bevarar Galerkin-ROM baserad på projektion samma polynomstruktur som $\mathbf{f}$ (2.2). Senare i detta arbete kommer vi att betrakta den enklare formen $\hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}})$ och utelämna insignalen $\mathbf{u}$ som variabel, då den inte är relevant för härledningen av vårt nya ramverk.

Inom MOR skiljer vi mellan:

- *Intrusivt tillvägagångssätt (projektionsbaserat)*: Kräver explicit tillgång till $\mathbf{c}$, $\mathbf{A}$, $\mathbf{H}$ och $\mathbf{B}$ för att kunna sätta samman de reducerade operatorerna. Detta kan vara komplicerat om den högtrogna lösaren är proprietär eller fungerar som en svart låda (*black-box*).
- *Icke-intrusivt tillvägagångssätt (datadrivet)*: Projicerar inte explicit $\mathbf{c}$, $\mathbf{A}$, $\mathbf{H}$ och $\mathbf{B}$. Istället samlas tidsseriedata in (ögonblicksbilder av $\mathbf{q}(t)$) och vid behov även $\dot{\mathbf{q}}(t)$, projiceras på $\mathbf{V}_r$, och de reducerade operatorerna lärs in via regression. Detta tillvägagångssätt är idealiskt om den ursprungliga lösaren är en svart låda eller om modifiering av den är orimligt komplex. Operatorinferens är en prototypisk icke-intrusiv metod.

I båda fallen genererar MOR-metoden en effektiv ersättningsmodell av det högdimensionella dynamiska systemet som opererar i ett underrum av betydligt lägre dimension. Som ett resultat möjliggörs snabbare simuleringar och analyser samtidigt som de väsentliga fysikaliska egenskaperna hos det ursprungliga systemet bevaras.

Ytterligare detaljer om projektionstekniker och praktiska implementeringsaspekter av POD-baserade ROM finns i [9].

2.2 Operatorinferens (OpInf)

Operatorinferens (OpInf) är en datadriven metod för modellreducering som kombinerar nyckelaspekter av projektionsbaserad modellreducering med datadrivna inlärningstekniker [3, 10]. Detta tillvägagångssätt möjliggör konstruktion av beräkningsmässigt effektiva reducerade ordningsmodeller, samtidigt som den fysikaliska tolkningsbarheten bibehålls genom att strukturen hos de styrande ekvationerna bevaras.

Metodikens allmänna beskrivning

Det grundläggande konceptet i OpInf ligger i att inferera operatorerna i en reducerad ordningsmodell genom en inlärningsprocess som utnyttjar både högtrogna simuleringsdata och den underliggande strukturen hos de styrande ekvationerna. Metoden opererar i tre huvudsteg:

1. **Datainsamling**: Samla in lösningens ögonblicksbilder $\{\mathbf{q}(t_i)\}_{i=1}^k$ och motsvarande insignaler från högtrogna numeriska simuleringar av den fullständiga ordningsmodellen.
2. **Tillståndspojektion**: Använda dimensionsreducerande tekniker, såsom modifierad ortogonalnedbrytning (POD), för att identifiera ett lågdimensionellt underrum som fångar den essentiella dynamiken. Detta projicerar det högdimensionella tillståndet $\mathbf{q}(t) \in \mathbb{R}^n$ till ett reducerat tillstånd $\hat{\mathbf{q}}(t) \in \mathbb{R}^r$, där $r \ll n$.

3. **Operatorinferens:** Bestäm de reducerade ordningsoperatorerna genom en minsta kvadrat-optimering som tvingar den inlärd modellen att anpassa sig till både projicerade data och strukturen hos de styrande ekvationerna.

Matematisk formulering

I sin kärna antar OpInf en polynomform för den reducerade dynamiken i det r -dimensionella underrummet och löser ett minsta kvadrat-problem för att inferera de reducerade operatorerna från data genom följande steg:

- 1) **Datainsamling.** Simulera eller experimentera med den fullständiga modellen (2.6) under ett eller flera insignalsscenarioer $\mathbf{u}(t)$, och lagra:

$$\{\mathbf{q}(t_i)\}_{i=1}^k \quad \text{och} \quad \{\dot{\mathbf{q}}(t_i)\}_{i=1}^k,$$

om de är direkt tillgängliga eller approximerade med finita differenser.

- 2) **Reducerad bas via POD och projektion till reducerade koordinater.** Bilda matrisen för ögonblicksbilder

$$\mathbf{Q} = [\mathbf{q}(t_1) \ \mathbf{q}(t_2) \ \dots \ \mathbf{q}(t_k)] \in \mathbb{R}^{n \times k}.$$

Beräkna dess trunkerade singularvärdesuppdelning för att erhålla $\mathbf{V}_r$ som i (2.7), där $r \ll n$ väljs baserat på singularvärdenas avtagande eller ett energitröskelvärde. Sedan, för varje ögonblicksbild,

$$\hat{\mathbf{q}}(t_i) = \mathbf{V}^T \mathbf{q}(t_i) \in \mathbb{R}^r, \quad \hat{\dot{\mathbf{q}}}(t_i) = \mathbf{V}^T \dot{\mathbf{q}}(t_i) \in \mathbb{R}^r.$$

- 3) **Anta en reducerad form och formulera ett regressionsproblem (minsta kvadrat-metoden).** Föreskriv en struktur för den r -dimensionella ODE:n. Ett vanligt val inkluderar konstanta, linjära, kvadratiska och reglertermer, varför vi definierar den diskreta träningsförlustfunktionen som

$$\sum_{i=1}^k \left\| \left[\hat{\mathbf{c}} + \hat{\mathbf{A}}\hat{\mathbf{q}}(t_i) + \hat{\mathbf{H}}[\hat{\mathbf{q}}(t_i) \otimes \hat{\mathbf{q}}(t_i)] + \hat{\mathbf{B}}\mathbf{u}(t_i) \right] - \hat{\dot{\mathbf{q}}}(t_i) \right\|_2^2, \quad (2.11)$$

där de reducerade operatorerna $\hat{\mathbf{c}}$, $\hat{\mathbf{A}}$, $\hat{\mathbf{H}}$ och $\hat{\mathbf{B}}$ är de element som ska infereras.

Slutligen identifierar OpInf de reducerade operatorerna genom och lösa följande minsta kvadrat-problem (en linjär regression i $\hat{\boldsymbol{\theta}}$) för att minimera träningsförlusten

$$\min_{\hat{\boldsymbol{\theta}} \in \hat{\boldsymbol{\Theta}}} \sum_{i=1}^k \left\| \left[\hat{\mathbf{c}} + \hat{\mathbf{A}}\hat{\mathbf{q}}(t_i) + \hat{\mathbf{H}}[\hat{\mathbf{q}}(t_i) \otimes \hat{\mathbf{q}}(t_i)] + \hat{\mathbf{B}}\mathbf{u}(t_i) \right] - \hat{\dot{\mathbf{q}}}(t_i) \right\|_2^2. \quad (2.12)$$

Användningen av polynomiska parametriseringar i operatorinferens motiveras av det faktum att många projektionsbaserade reducerade ordningsmodeller av PDE:er

naturligt antar en polynomform. Till exempel leder semidiskretisering av den viskösa Burgers ekvation typiskt till ett system av fullständiga ODE:er med kvadratiska ickelinjäriteter. En efterföljande Galerkinprojektion på en POD-bas genererar då ett kvadratiskt reducerat system.

I icke-intrusiv modellreducering, såsom OpInf, beräknar vi inte de reducerade operatorerna via Galerkinprojektion, eftersom detta skulle kräva tillgång till de interna komponenterna i fullordningslösaren. Istället infereras de reducerade operatorerna direkt från data. Detta tillvägagångssätt antar att träningsdata återspeglar en polynomstruktur som är kompatibel med den valda modellformen.

När det ursprungliga systemet involverar icke-polynomiska ickelinjäriteter kan detta antagande fallera, vilket resulterar i sämre modellprestanda. I sådana fall kan en lyfttransformering (*lifting transformation*) tillämpas för att skriva om systemet i ett högdimensionellt rum där dynamiken uppvisar en polynomstruktur. Dessa lyftavbildningar, som ofta introducerar hjälpvariabler, gör det möjligt för operatorinferens att approximera systemet med högre noggrannhet genom att anpassa data till modellens polynomstruktur.

I praktiken är det också vanligt att inkludera en regulariseringsterm i träningsförlusten, $\mathcal{R}(\hat{\theta})$ i (2.12), vilken besträffar storleken på elementen i de inlärda operatorerna. Denna regularisering förbättrar konditioneringen av inlärningsproblemet. För ytterligare detaljer och numeriska implementeringar hänvisas läsaren till online-resursen [9] och det banbrytande arbetet av Peherstorfer och Willcox [3].

Fördelar och tillämpningar

Operatorinferens erbjuder flera distinkta fördelar jämfört med traditionella tillvägagångssätt för modellreducering:

- **Icke-intrusiv:** Kräver endast ögonblicksbilder av lösningen istället för explicit tillgång till fullordningsmodellens operatorer.
- **Fysikmedveten (*physics-aware*):** Galerkinprojektion bevarar polynomstrukturen hos de styrande fullordningsekvationerna i det reducerade systemet. Faktum är att en jämförelse term för term av (2.2) och (2.10) bekräftar denna unika korrespondens.
- **Beräkningsmässigt effektiv:** Undviker kostsamma operationer i hög dimension genom dimensionsreducering.

Denna metodik har framgångsrikt tillämpats på olika komplexa dynamiska system, inklusive strömningsmekanik, termiska system och strukturdynamik [4, 11]. Kombinationen av datadriven inlärning med fysikbaserade bivillkor gör operatorinferens särskilt effektiv för system där traditionella projektionsbaserade metoder blir beräkningsmässigt oöverkomliga eller där fullordningsmodellens operatorer inte är explicit tillgängliga. Trots dessa styrkor är en central begränsning hos OpInf dess beroende av noggrann beräkning av tidsderivator från data, vilket kan äventyras avsevärt när tillgängliga data är imperfekt

eller brusig. I nästa kapitel introducerar vi ett nytt tillvägagångssätt designat för att övervinna denna utmaning, vilket förbättrar robustheten och noggrannheten hos de infererade reducerade operatorerna.

ADJUNKTMETOD FÖR INFERENS AV OPERATORER

3.1 En förlustfunktional i kontinuerlig tid

För härledningen av detta nya ramverk antas en kontinuerlig bana $\hat{\mathbf{q}}(t) \in \mathcal{C}^1(\mathcal{T})^r$ över en tidsdomän $\mathcal{T} = [0, T]$. I praktiken har vi dock endast tillgång till diskreta tidsögonblicksbilder $\{(t_i, \mathbf{q}_{\text{true}}(t_i))\}_{i=1}^k$. För att genomföra övergången från diskret till kontinuerlig tid approximerar vi kostnadssummemfunktionen g medelst interpolation (se Bilaga A.2 – Kubiska splines) [12]:

$$\sum_{i=1}^k \underbrace{\|\hat{\mathbf{q}}_{\text{true}}(t_i) - \tilde{\mathbf{q}}(t_i, \hat{\boldsymbol{\theta}})\|_2^2}_{g(\tilde{\mathbf{q}}(t_i, \hat{\boldsymbol{\theta}}), t_i)} \Delta t \xrightarrow{\text{interp.}} \int_0^T \underbrace{\|\hat{\mathbf{q}}_{\text{true}}(t) - \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})\|_2^2}_{g(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), t)} dt,$$

där $\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})$ betecknar den reducerade predikterade bana som genereras av vår dynamiska modell (det vill säga lösningen till (2.10)). Eftersom $\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})$ genereras utifrån de diskreta referensögonblicksbilderna ("ground-truth") $\{\mathbf{q}_{\text{true}}(t_i)\}$, behöver vi endast interpolera dessa värden för $\mathbf{q}_{\text{true}}(t_i)$ i tiden.

För att undvika den explicita differentiering som karakteriserar standardmetoden för OpInf, introducerar vi en förlustfunktional i kontinuerlig tid som i L^2 -mening jämför den rekonstruerade banan, erhållen genom integration av de inlärdade operatorerna, med observerade data.

Definition 3.1.1 *Betrakta högerledet i det reducerade systemet, det vill säga $\hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}})$, som i (2.10), för en given insignal $\mathbf{u}(t)$ över tidsdomänen $\mathcal{T} = [0, T]$. Låt $\hat{\mathbf{q}} \in \mathcal{C}^1(\mathcal{T})^r$ vara den reducerade banan och $[\hat{\mathbf{c}} \hat{\mathbf{A}} \hat{\mathbf{H}} \hat{\mathbf{B}}] = \hat{\boldsymbol{\theta}} \in \mathbb{R}^d$ vara vektorn av alla reducerade operatorer, med totalt $d = r + r^2 + r^3 + rm$ parametrar. Vi definierar träningsförlustfunktionalen i kontinuerlig tid $\ell(\hat{\mathbf{q}}(t))$ som diskrepansen mellan observerade och predikterade data, det vill säga*

$$\ell : \mathcal{C}^1(\mathcal{T})^r \rightarrow \mathbb{R}, \quad \hat{\mathbf{q}}(\cdot) \mapsto \int_0^T \left\| \hat{\mathbf{q}}(t) - \hat{\mathbf{q}}_{\text{true}}(t) \right\|_2^2 dt = \int_0^T g(\hat{\mathbf{q}}(t), t) dt, \quad (3.1)$$

där $g(\hat{\mathbf{q}}(t), t) := \left\| \hat{\mathbf{q}}(t) - \hat{\mathbf{q}}_{\text{true}}(t) \right\|_2^2$. Vi definierar den reducerade förlustfunktionalen som

$$\tilde{\ell} : \mathbb{R}^d \rightarrow \mathbb{R}, \quad \hat{\boldsymbol{\theta}} \mapsto \int_0^T \left\| \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}) - \hat{\mathbf{q}}_{\text{true}}(t) \right\|_2^2 dt, \quad (3.2)$$

där

$$\begin{aligned} \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}) &= \tilde{\mathbf{q}}(0) + \int_0^t \hat{\mathbf{f}}(\tilde{\mathbf{q}}(\tau), \hat{\boldsymbol{\theta}}) d\tau \\ &= \tilde{\mathbf{q}}(0) + \int_0^t \left[\hat{\mathbf{c}} + \hat{\mathbf{A}}\tilde{\mathbf{q}}(\tau) + \hat{\mathbf{H}}(\tilde{\mathbf{q}}(\tau) \otimes \tilde{\mathbf{q}}(\tau)) + \hat{\mathbf{B}}\mathbf{u}(\tau) \right] d\tau, \quad t \in \mathcal{T} \end{aligned} \quad (3.3)$$

är lösningen till

$$\dot{\hat{\mathbf{q}}}(t) = \hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}}), \quad \hat{\mathbf{q}}(0) = \hat{\mathbf{q}}_0, \quad (3.4)$$

för ett givet $\hat{\boldsymbol{\theta}}$.

Observera att $\tilde{\ell}(\hat{\boldsymbol{\theta}}) = \ell(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}))$ eftersom $\tilde{\mathbf{q}}$ uppfyller den styrande ekvationen av reducerad ordning (3.4).

Baserat på den reducerade förlustfunktionalen (3.2), som beaktar tidsintegralen av högerledet i vårt reducerade dynamiska system, består inlärningsuppgiften i att finna

$$\hat{\boldsymbol{\theta}}^* = \min_{\hat{\boldsymbol{\theta}}} \tilde{\ell}(\hat{\boldsymbol{\theta}}). \quad (3.5)$$

För att differentiera funktionaler påminner vi först om Gâteaux-derivatan [13]:

Definition 3.1.2 För en avbildning $\mathbf{f} : \mathcal{X} \rightarrow \mathcal{Y}$ mellan normerade rum definieras Gâteaux-derivatan av $\mathbf{f}$ i $\mathbf{x}$ i ”riktningen” $\mathbf{v}$ som

$$\mathbf{D}_{\mathbf{x}} \mathbf{f}(\mathbf{x}; \mathbf{v}) := \lim_{\varepsilon \rightarrow 0} \frac{\mathbf{f}(\mathbf{x} + \varepsilon \mathbf{v}) - \mathbf{f}(\mathbf{x})}{\varepsilon},$$

förutsatt att detta gränsvärde existerar.

Det bör noteras att indexet $\mathbf{x}$ betecknar differentiering med avseende på denna variabel, i synnerhet när $\hat{\mathbf{f}}$ beror på flera variabler. För att minimera den reducerade förlustfunktionalen beräknar vi den totala gradienten med avseende på parametrarna. Enligt kedjeregeln har vi:

$$\frac{d\tilde{\ell}(\hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} = \frac{d\ell(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}))}{d\hat{\boldsymbol{\theta}}} = \underbrace{\frac{\partial \ell}{\partial \hat{\boldsymbol{\theta}}}}_{\text{direkt beroende} = 0} + \underbrace{\frac{\partial \ell}{\partial \tilde{\mathbf{q}}}}_{\text{implicit beroende}} \bigg|_{\tilde{\mathbf{q}}(\cdot) = \tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})} \cdot \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}}, \quad (3.6)$$

där termen $d\tilde{\mathbf{q}}/d\hat{\boldsymbol{\theta}}$ kodar hur den reducerade banan förändras vid variationer i parametrarna. Eftersom ℓ inte har något direkt beroende av $\hat{\boldsymbol{\theta}}$ försvinner den första termen. Vi inser nu att

$$\frac{\partial \ell}{\partial \tilde{\mathbf{q}}} \bigg|_{\tilde{\mathbf{q}}(\cdot) = \tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})}$$

är derivatan av en funktional med avseende på en funktion. Genom att använda notationen introducerad i 3.1.2 skriver vi

$$\frac{\partial \ell}{\partial \tilde{\mathbf{q}}} \bigg|_{\tilde{\mathbf{q}}(\cdot) = \tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})} \cdot \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} = \mathbf{D} \ell \left(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}); \frac{d\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} \right).$$

Direkt beräkning av denna känslighet $d\tilde{\mathbf{q}}/d\hat{\boldsymbol{\theta}}$ är kostsam och benägen att drabbas av numerisk instabilitet. För att kringgå denna svårighet använder vi adjunktmetoden, vilken omformulerar gradienten i termer av en adjunkt variabel som uppfyller en differentialekvation bakåt i tiden (*backward-in-time*). I Figur 3.1 illustreras en allmän beskrivning av minimeringsprocessen (OpInf jämfört med adjunktmetoden).

3.2 Ekvationerna för det adjunkta tillståndet

Problemformulering

För en given samling av ögonblicksbilddata betraktar vi dess motsvarande interpolerade kontinuerliga sanna data $\hat{\mathbf{q}}_{\text{true}}(\cdot)$. Vi formulerar minimeringen av förlusten som ett optimeringsproblem med likhetsvillkor enligt tillvägagångssättet i [7], det vill säga:

$$\begin{aligned} \min_{\hat{\boldsymbol{\theta}}} \tilde{\ell}(\hat{\boldsymbol{\theta}}) &\equiv \min_{\hat{\boldsymbol{\theta}}, \hat{\mathbf{q}}(\cdot)} \ell(\hat{\mathbf{q}}(\cdot)) \\ \text{s.t. } \dot{\hat{\mathbf{q}}}(t) &= \hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}}), \quad \hat{\mathbf{q}}(0) = \hat{\mathbf{q}}_0, \quad t \in [0, T], \end{aligned} \quad (3.7)$$

där ℓ , $\tilde{\ell}$ är förlustfunktionalerna definierade i (3.1) och (3.2), och villkoret representerar ROM-OpInf-systemet beskrivet i (2.10).

Observera da att i den gemensamma minimeringen (3.7) beror förlustfunktionalen ℓ uteslutande på banan $\hat{\mathbf{q}}(\cdot)$, vilken mäter avvikelserna med avseende på sanna data $\hat{\mathbf{q}}_{\text{true}}(\cdot)$, och beror inte explicit på $\hat{\boldsymbol{\theta}}$. Följaktligen, när vi skriver

$$\min_{\hat{\boldsymbol{\theta}}, \hat{\mathbf{q}}(\cdot)} \ell(\hat{\mathbf{q}}(\cdot)),$$

underförstås att ℓ endast utvärderas över $\hat{\mathbf{q}}(\cdot)$, medan $\hat{\boldsymbol{\theta}}$ intervenerar uteslutande via villkoret

$$\dot{\hat{\mathbf{q}}}(t) = \hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}}).$$

Lagrange-funktionen associerad med (3.7) definieras som

$$\mathcal{L}(\hat{\mathbf{q}}(\cdot), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) := \ell(\hat{\mathbf{q}}(\cdot)) - \int_0^T \boldsymbol{\lambda}(t)^\top (\dot{\hat{\mathbf{q}}}(t) - \hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}})) dt - \boldsymbol{\lambda}(0)^\top (\hat{\mathbf{q}}(0) - \hat{\mathbf{q}}_0). \quad (3.8)$$

Eftersom villkoren är exakt uppfyllda för den optimala banan $\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})$, följer det att

$$\mathcal{L}(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) = \tilde{\ell}(\hat{\boldsymbol{\theta}}), \quad (3.9)$$

vilket är giltigt för alla $\boldsymbol{\lambda}(\cdot) \in \mathcal{C}^1([0, T])^r$.

Med syftet att utföra en gradientbaserad optimeringsprocess krävs beräkning av

$$\begin{aligned} \frac{d\tilde{\ell}(\hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} &= \frac{d\mathcal{L}}{d\hat{\boldsymbol{\theta}}}(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) \\ &= \frac{\partial \mathcal{L}}{\partial \hat{\boldsymbol{\theta}}} + \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{q}}} \bigg|_{\hat{\mathbf{q}}(\cdot) = \tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})} \cdot \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} \\ &= \frac{\partial \mathcal{L}}{\partial \hat{\boldsymbol{\theta}}} + \mathbf{D}_{\tilde{\mathbf{q}}} \mathcal{L} \left(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot); \frac{d\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} \right). \end{aligned} \quad (3.10)$$

Härefter påtvingar vi stationaritetsvillkoret för derivatan,

$$\frac{\partial \mathcal{L}}{\partial \hat{\mathbf{q}}} \bigg|_{\hat{\mathbf{q}}(\cdot) = \tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})} = \mathbf{0}.$$

Detta villkor kommer att tillhandahålla de nödvändiga adjunkta ekvationerna för att bestämma $\boldsymbol{\lambda}$, vilket säkerställer att

$$\frac{d\tilde{\ell}(\hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} = \frac{\partial \mathcal{L}}{\partial \hat{\boldsymbol{\theta}}}(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)). \quad (3.11)$$

För nämnda problem ger den klassiska adjunktmetoden, så som den formuleras i [7, 14], följande resultat.

Teorem 3.2.1 (Adjunktmetoden) Anta att $\hat{\mathbf{f}}$ och g är kontinuerligt differentierbara i både $\hat{\mathbf{q}}$ och $\hat{\boldsymbol{\theta}}$, samt att det initiala tillståndet $\hat{\mathbf{q}}(0) = \hat{\mathbf{q}}_0$ är fixerat (oberoende av $\hat{\boldsymbol{\theta}}$). Den adjunkta variabeln $\boldsymbol{\lambda}(t) \in \mathcal{C}^1(\mathcal{T})^r$ associerad med ett minimeringsproblem som det i (3.7) uppfyller en ordinär differentialekvation (ODE) med bakåtfatsspridning

$$\dot{\boldsymbol{\lambda}}(t) = - \left[\left(\frac{\partial \hat{\mathbf{f}}}{\partial \hat{\mathbf{q}}} \right)^\top \boldsymbol{\lambda}(t) + \left(\frac{\partial g}{\partial \hat{\mathbf{q}}} \right)^\top \right] \Big|_{\hat{\mathbf{q}}(\cdot) = \hat{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})}, \quad \boldsymbol{\lambda}(T) = \mathbf{0}. \quad (3.12)$$

Vidare antar gradienten för $\tilde{\ell}$ med avseende på parametrarna för träningsförlusten i (3.2) formen

$$\frac{d\tilde{\ell}(\hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} = \int_0^T \boldsymbol{\lambda}(t)^\top \frac{\partial \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}})}{\partial \hat{\boldsymbol{\theta}}} \Big|_{\hat{\mathbf{q}}(\cdot) = \hat{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}})} dt, \quad (3.13)$$

där $\boldsymbol{\lambda}$ är lösningen till (3.12).

Bevis (Lagrange-formulering)

Teorem (3.2.1) och dess bevis har inspirerats av de idéer och exempel som presenteras i [6, 7], varvid de väsentliga nyckelstegen har anpassats till vårt problem och våra antaganden.

Betrakta Lagrange-funktionen ($\mathcal{L}$) definierad som

$$\begin{aligned} \mathcal{L}(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) \\ &:= \ell(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})) - \int_0^T \boldsymbol{\lambda}(t)^\top (\dot{\tilde{\mathbf{q}}}(t, \hat{\boldsymbol{\theta}}) - \hat{\mathbf{f}}(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}})) dt - \boldsymbol{\lambda}(0)^\top (\tilde{\mathbf{q}}(0, \hat{\boldsymbol{\theta}}) - \tilde{\mathbf{q}}_0) \\ &= \int_0^T (g(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), t) - \boldsymbol{\lambda}(t)^\top (\dot{\tilde{\mathbf{q}}}(t) - \hat{\mathbf{f}}(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}))) dt - \boldsymbol{\lambda}(0)^\top (\tilde{\mathbf{q}}(0, \hat{\boldsymbol{\theta}}) - \tilde{\mathbf{q}}_0). \end{aligned}$$

Genom att differentiera Lagrange-funktionen med avseende på $\hat{\boldsymbol{\theta}}$ erhåller vi

$$\begin{aligned} \frac{d\mathcal{L}}{d\hat{\boldsymbol{\theta}}}(\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) \\ &= \int_0^T \left[\frac{\partial g}{\partial \hat{\boldsymbol{\theta}}} + \frac{\partial g}{\partial \tilde{\mathbf{q}}} \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} - \boldsymbol{\lambda}(t)^\top \left(\frac{d}{dt} \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} - \frac{\partial \hat{\mathbf{f}}}{\partial \hat{\boldsymbol{\theta}}} - \frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} \right) \right] dt - \boldsymbol{\lambda}(0)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}}(0) \\ &= \int_0^T \left[\frac{\partial g}{\partial \hat{\boldsymbol{\theta}}} + \boldsymbol{\lambda}(t)^\top \frac{\partial \hat{\mathbf{f}}}{\partial \hat{\boldsymbol{\theta}}} + \left(\frac{\partial g}{\partial \tilde{\mathbf{q}}} + \boldsymbol{\lambda}(t)^\top \frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} - \boldsymbol{\lambda}(t)^\top \frac{d}{dt} \right) \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} \right] dt - \boldsymbol{\lambda}(0)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}}(0). \end{aligned}$$

I syfte att undvika beräkningen av $d\tilde{\mathbf{q}}/d\hat{\boldsymbol{\theta}}$ (det vill säga banans känslighet med avseende på parametrarna, vars erhållande kan vara extremt komplext), tillämpar vi ett variabelbyte via adjunktmetoden. Genom partiell integration eliminerar vi termen $\frac{d}{dt} \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}}$ i den sista delen

av föregående integral:

$$\begin{aligned} \int_0^T -\boldsymbol{\lambda}(t)^\top \frac{d}{dt} \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} dt &= \left[-\boldsymbol{\lambda}(t)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} \right]_0^T + \int_0^T \left(\frac{d\boldsymbol{\lambda}}{dt} \right)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} dt \\ &= \boldsymbol{\lambda}(0)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} (0) - \boldsymbol{\lambda}(T)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} (T) + \int_0^T \left(\frac{d\boldsymbol{\lambda}}{dt} \right)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} dt. \end{aligned}$$

Vid insättning av detta uttryck resulterar derivatan av Lagrange-funktionen i

$$\begin{aligned} \frac{d\mathcal{L}}{d\hat{\boldsymbol{\theta}}} (\tilde{\mathbf{q}}(\cdot, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) &= \int_0^T \left[\frac{\partial g}{\partial \hat{\boldsymbol{\theta}}} + \boldsymbol{\lambda}(t)^\top \frac{\partial \hat{\mathbf{f}}}{\partial \hat{\boldsymbol{\theta}}} + \underbrace{\left(\frac{\partial g}{\partial \tilde{\mathbf{q}}} + \boldsymbol{\lambda}(t)^\top \frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} + \dot{\boldsymbol{\lambda}}(t)^\top \right)}_{\text{nollställs}=0} \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} \right] dt \\ &\quad - \boldsymbol{\lambda}(0)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} (0) + \boldsymbol{\lambda}(0)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} (0) - \underbrace{\boldsymbol{\lambda}(T)^\top \frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}} (T)}_{\text{nollställs}=0}. \end{aligned}$$

Vi inser att den uppsättning termer som multiplicerar känsligheten $\frac{d\tilde{\mathbf{q}}}{d\hat{\boldsymbol{\theta}}}$ motsvarar uttrycket $\frac{\partial \mathcal{L}}{\partial \tilde{\mathbf{q}}}$, vilket vi nollställer tillsammans med terminalvillkoret $\boldsymbol{\lambda}(T) = \mathbf{0}$. Eftersom $\boldsymbol{\lambda}$ är godtycklig är ekvation (3.9) uppfylld för alla dess värden. Efter transponering och omorganisering av termerna erhåller vi de önskade adjunkta ekvationerna:

$$\dot{\boldsymbol{\lambda}}(t) = - \left[\left(\frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \right)^\top \boldsymbol{\lambda}(t) + \left(\frac{\partial g}{\partial \tilde{\mathbf{q}}} \right)^\top \right], \quad \boldsymbol{\lambda}(T) = \mathbf{0}.$$

Å andra sidan, som vi visade i problemformuleringen (3.10), är minimering av Lagrange-funktionen $\mathcal{L}$ ekvivalent med minimering av förlustfunktionalen $\tilde{\ell}$. Likaså beror g per definition inte på $\hat{\boldsymbol{\theta}}$, vilket innebär att $\frac{\partial g}{\partial \hat{\boldsymbol{\theta}}} = \mathbf{0}$. Följaktligen är det slutgiltiga uttrycket för gradienten:

$$\frac{d\tilde{\ell}(\hat{\boldsymbol{\theta}})}{d\hat{\boldsymbol{\theta}}} = \int_0^T \boldsymbol{\lambda}^\top \frac{\partial \hat{\mathbf{f}}(\tilde{\mathbf{q}}, \hat{\boldsymbol{\theta}})}{\partial \hat{\boldsymbol{\theta}}} dt.$$

Detta fullbordar beviset. □

Anmärkning 3.2.2 För att utvärdera den adjunkta ekvationen (3.12) i praktiken integreras först den reducerade framåtmodellen (forward model) för att erhålla $\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})$ på intervallet $[0, T]$. Därefter, med användning av $\hat{\mathbf{q}}(t) = \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})$, löses den adjunkta ODE:n (3.12) bakåt i tiden, från $t = T$ till $t = 0$.

Formulering för den kvadratiska strukturen

Vi betraktar nu den kvadratiske OpInf-strukturen som tidigare etablerades i (2.2) i syfte att härleda de specifika adjunkta ekvationerna för detta problem. Denna härledning hämtar inspiration från anteckningarna av [15]. Av bekvämlighetsskäl betecknar vi villkorsekvationen som

$$\mathbf{c}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}}) := \dot{\hat{\mathbf{q}}}(t) - \hat{\mathbf{c}} - \hat{\mathbf{A}}\hat{\mathbf{q}}(t) - \hat{\mathbf{H}}[\hat{\mathbf{q}}(t) \otimes \hat{\mathbf{q}}(t)] - \hat{\mathbf{B}}\mathbf{u}.$$

Här är tensoroperatoren $\hat{\mathbf{H}} \in \mathbb{R}^{r \times r^2}$ Kronecker-symmetrisk, det vill säga $\hat{\mathbf{H}}[\hat{\mathbf{q}} \otimes \mathbf{v}] = \hat{\mathbf{H}}[\mathbf{v} \otimes \hat{\mathbf{q}}]$. På detta sätt kan Lagrange-funktionen (målfunktionen minus produkten av den adjunkta variabeln och villkoret, minus randtermen för begynnelsevillkoret) skrivas om som

$$\begin{aligned} \mathcal{L}(\hat{\mathbf{q}}(\cdot), \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}(\cdot)) &= \ell(\hat{\mathbf{q}}(\cdot)) - \int_0^T \boldsymbol{\lambda}(t)^\top \mathbf{c}(\hat{\mathbf{q}}(t), \hat{\boldsymbol{\theta}}) dt - \boldsymbol{\lambda}(0)^\top (\hat{\mathbf{q}}(0) - \hat{\mathbf{q}}_0) \\ &= \int_0^T g(\hat{\mathbf{q}}(t), t) dt \\ &\quad - \int_0^T \boldsymbol{\lambda}(t)^\top (\dot{\hat{\mathbf{q}}}(t) - \hat{\mathbf{c}} - \hat{\mathbf{A}}\hat{\mathbf{q}}(t) - \hat{\mathbf{H}}(\hat{\mathbf{q}}(t) \otimes \hat{\mathbf{q}}(t)) - \hat{\mathbf{B}}\mathbf{u}(t)) dt \\ &\quad - \boldsymbol{\lambda}(0)^\top (\hat{\mathbf{q}}(0) - \hat{\mathbf{q}}_0), \end{aligned}$$

där den adjunkta variabeln $\boldsymbol{\lambda}(\cdot) \in \mathcal{C}^1(\mathcal{T})^r$ har samma dimension som tillståndsvariabeln $\hat{\mathbf{q}}(\cdot)$. Den adjunkta ekvationen för $\boldsymbol{\lambda}(\cdot)$ härleds genom att påtvinga villkoret att riktningsderivatan (Gâteaux-derivatan) ska vara noll:

$$\mathbf{D}_{\hat{\mathbf{q}}} \mathcal{L}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda}; \mathbf{v}) = \frac{d}{d\varepsilon} [\mathcal{L}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}}, \boldsymbol{\lambda})]_{\varepsilon=0} = \mathbf{0} \quad \forall \mathbf{v} \in \mathcal{C}^1(\mathcal{T})^r.$$

Genom att först observera att

$$\begin{aligned} \frac{d}{d\varepsilon} [\ell(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}})]_{\varepsilon=0} &= \int_0^T \frac{d}{d\varepsilon} [g(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, t)]_{\varepsilon=0} dt = \int_0^T \nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}, t)^\top \mathbf{v} dt, \\ \frac{d}{d\varepsilon} [\mathbf{c}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}})]_{\varepsilon=0} &= \dot{\mathbf{v}} - \hat{\mathbf{A}}\mathbf{v} - 2\hat{\mathbf{H}}[\hat{\mathbf{q}} \otimes \mathbf{v}], \end{aligned}$$

kan de adjunkta ekvationerna ställas upp på följande form:

$$\begin{aligned} \mathbf{0} &= \int_0^T \nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}(t), t)^\top \mathbf{v}(t) dt \\ &\quad - \int_0^T \boldsymbol{\lambda}(t)^\top (\dot{\mathbf{v}}(t) - \hat{\mathbf{A}}\mathbf{v}(t) - 2\hat{\mathbf{H}}[\hat{\mathbf{q}}(t) \otimes \mathbf{v}(t)]) dt - \boldsymbol{\lambda}(0)^\top \mathbf{v}(0). \end{aligned}$$

Vi söker att uttrycka dessa adjunkta ekvationer på svag form genom att använda en testfunktion $\mathbf{v}$. Partiell integration av tids-termen ger

$$\begin{aligned}
-\int_0^T \boldsymbol{\lambda}(t)^\top \dot{\mathbf{v}}(t) dt &= -[\boldsymbol{\lambda}(t)^\top \mathbf{v}(t)]_0^T + \int_0^T \dot{\boldsymbol{\lambda}}(t)^\top \mathbf{v}(t) dt \\
&= \boldsymbol{\lambda}(0)^\top \mathbf{v}(0) - \boldsymbol{\lambda}(T)^\top \mathbf{v}(T) + \int_0^T \mathbf{v}(t)^\top \dot{\boldsymbol{\lambda}}(t) dt.
\end{aligned}$$

Genom att använda denna identitet och transponera varje (skalär) term, transformeras de adjunkta ekvationerna till

$$\mathbf{0} = \int_0^T \mathbf{v}(t)^\top \left(\dot{\boldsymbol{\lambda}}(t) + \hat{\mathbf{A}}^\top \boldsymbol{\lambda}(t) + 2\tilde{\mathbf{H}}[\hat{\mathbf{q}}(t) \otimes \boldsymbol{\lambda}(t)] + \nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}(t), t) \right) dt - \mathbf{v}(T)^\top \boldsymbol{\lambda}(T),$$

där $\tilde{\mathbf{H}} \in \mathbb{R}^{r \times r^2}$ är den matris som uppfyller relationen

$$\boldsymbol{\lambda}^\top \tilde{\mathbf{H}}[\hat{\mathbf{q}} \otimes \mathbf{v}] = \mathbf{v}^\top \tilde{\mathbf{H}}[\hat{\mathbf{q}} \otimes \boldsymbol{\lambda}], \quad \forall \hat{\mathbf{q}}, \mathbf{v}, \boldsymbol{\lambda} \in \mathbb{R}^r.$$

Eftersom $\mathbf{v}$ är helt godtycklig identifierar vi föregående uttryck som den svaga formen associerad med följande ekvation på stark form:

$$-\dot{\boldsymbol{\lambda}}(t) = \hat{\mathbf{A}}^\top \boldsymbol{\lambda}(t) + 2\tilde{\mathbf{H}}[\hat{\mathbf{q}}(t) \otimes \boldsymbol{\lambda}(t)] + \nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}(t), t), \quad \boldsymbol{\lambda}(T) = \mathbf{0}, \quad t \in [0, T].$$

Detta linjära (men icke-autonoma) system kan lösas med tidsintegration bakåt (*backward time-integration*) givet en beräknad tillstånds-bana $\hat{\mathbf{q}}(t)$. Systemet kan uttryckas på en mer explicit linjär form med avseende på $\boldsymbol{\lambda}(t)$ som

$$\begin{aligned}
\dot{\boldsymbol{\lambda}}(t) &= -\left(\hat{\mathbf{A}}^\top + 2\mathbf{M}(\hat{\mathbf{q}}(t))\right) \boldsymbol{\lambda}(t) - \nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}(t), t), \\
&= -\nabla_{\hat{\mathbf{q}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}(t), \boldsymbol{\theta}) \boldsymbol{\lambda}(t) - \nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}(t), t),
\end{aligned} \tag{3.14}$$

där $\mathbf{M}(\hat{\mathbf{q}}(t)) \in \mathbb{R}^{r \times r}$ är den matris som definieras så att

$$\mathbf{M}(\hat{\mathbf{q}}(t)) \boldsymbol{\lambda} = \tilde{\mathbf{H}}[\hat{\mathbf{q}}(t) \otimes \boldsymbol{\lambda}].$$

Vi skjuter upp den detaljerade beräkningen av $\nabla_{\hat{\mathbf{q}}} g$, tillsammans med de återstående gradienter som krävs för adjunktmetoden, till Avsnitt 3.3.

Alternativt bevis (Känslighetsanalys av det primala problemet)

Ett alternativt tillvägagångssätt för att bevisa Teorem 3.2.1, föreslaget av handledningen, ger följande härledning. Det inkluderas i detta dokument eftersom det bidrar med ett mycket värdefullt och komplementärt analytiskt perspektiv på problemet.

Vi utgår från de *primala* känslighetsekvationerna associerade med tillståndslösningen $\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}})$ och parametrarna $\hat{\theta}_i$ för $i = 1, \dots, d$:

$$\dot{\tilde{\mathbf{q}}}(t) = \hat{\mathbf{f}}(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}), \quad \partial_{\hat{\theta}_i} \dot{\tilde{\mathbf{q}}}(t) = \frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}}(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}})^\top \partial_{\hat{\theta}_i} \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}) + \partial_{\hat{\theta}_i} \hat{\mathbf{f}}(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), \hat{\boldsymbol{\theta}}).$$

Genom att multiplicera den andra ekvationen med en godtycklig testfunktion $\mathbf{v}(\cdot) \in \mathcal{C}^1(\mathcal{T})^r$, integrera över intervallet $[0, T]$ och omorganisera termerna, kan vi skriva om det primala problemet på svag form:

$$\int_0^T \left[\partial_{\hat{\theta}_i} \dot{\tilde{\mathbf{q}}}(t, \hat{\boldsymbol{\theta}}) - \left(\frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \right)^\top \partial_{\hat{\theta}_i} \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}) \right]^\top \mathbf{v}(t) dt = \int_0^T (\partial_{\hat{\theta}_i} \hat{\mathbf{f}})^\top \mathbf{v}(t) dt,$$

eller, med användning av operatornotation,

$$\langle \mathcal{L} \partial_{\hat{\theta}_i} \tilde{\mathbf{q}}, \mathbf{v} \rangle = \langle \partial_{\hat{\theta}_i} \hat{\mathbf{f}}, \mathbf{v} \rangle,$$

där operatoren

$$\mathcal{L} : \mathcal{C}^1(\mathcal{T})^r \rightarrow \mathcal{C}^0(\mathcal{T})^r,$$

med definitionsmängd och värdemängd utrustade med den sedvanliga inre produkten för L^2 (betecknad med $\langle \cdot, \cdot \rangle$), ges av

$$(\mathcal{L} \mathbf{w})(t) = \dot{\mathbf{w}}(t) - \left(\frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \right)^\top \mathbf{w}(t),$$

för varje funktion $\mathbf{w}(\cdot) \in \mathcal{C}^1(\mathcal{T})^r$.

Å andra sidan är gradienten för förlustfunktionen $\tilde{\ell}$ med avseende på parameterkomponenten $\hat{\theta}_i$ lika med

$$\frac{d}{d\hat{\theta}_i} \tilde{\ell} = \int_0^T \frac{\partial g}{\partial \tilde{\mathbf{q}}}(\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}), t)^\top \partial_{\hat{\theta}_i} \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}) dt = \langle \nabla_{\tilde{\mathbf{q}}} g, \partial_{\hat{\theta}_i} \tilde{\mathbf{q}} \rangle.$$

Nu definierar vi det adjunkta problemet genom att introducera en adjunkt variabel $\boldsymbol{\lambda}(\cdot) \in \mathcal{C}^1(\mathcal{T})^r$ sådan att

$$\langle \mathbf{w}, \tilde{\mathcal{L}} \boldsymbol{\lambda} \rangle = \langle \nabla_{\tilde{\mathbf{q}}} g, \mathbf{w} \rangle \quad \forall \mathbf{w}(\cdot) \in \mathcal{C}^1(\mathcal{T})^r \text{ med } \mathbf{w}(0) = \mathbf{0},$$

där $\tilde{\mathcal{L}}$ är den adjunkta operatoren till $\mathcal{L}$. Enligt definitionen av en adjunkt operator är detta ekvivalent med att skriva

$$\langle \mathcal{L} \mathbf{w}, \boldsymbol{\lambda} \rangle = \langle \nabla_{\tilde{\mathbf{q}}} g, \mathbf{w} \rangle.$$

Genom att specifikt välja $\mathbf{w} = \partial_{\hat{\theta}_i} \tilde{\mathbf{q}}$ i denna identitet erhålls omedelbart och direkt:

$$\frac{d}{d\hat{\theta}_i} \tilde{\ell} = \langle \mathcal{L} \partial_{\hat{\theta}_i} \tilde{\mathbf{q}}, \boldsymbol{\lambda} \rangle \underset{\substack{\text{primalt problem} \\ \text{med } \mathbf{v} = \boldsymbol{\lambda}}}{=} \langle \partial_{\hat{\theta}_i} \hat{\mathbf{f}}, \boldsymbol{\lambda} \rangle = \int_0^T \boldsymbol{\lambda}^\top \partial_{\hat{\theta}_i} \hat{\mathbf{f}}(t, \hat{\boldsymbol{\theta}}) dt.$$

För att härleda själva den adjunkta ODE:n expanderar vi den strukturella relationen:

$$\langle \mathcal{L} \mathbf{w}, \boldsymbol{\lambda} \rangle = \int_0^T \left[\dot{\mathbf{w}}(t) - \left(\frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \right)^\top \mathbf{w}(t) \right]^\top \boldsymbol{\lambda}(t) dt = \int_0^T \left(\frac{\partial g}{\partial \tilde{\mathbf{q}}} \right)^\top \mathbf{w}(t) dt = \langle \nabla_{\tilde{\mathbf{q}}} g, \mathbf{w} \rangle.$$

Genom partiell integration av tidsderivata-termen

$$\int_0^T \dot{\mathbf{w}}(t)^\top \boldsymbol{\lambda}(t) dt = [\mathbf{w}(t)^\top \boldsymbol{\lambda}(t)]_0^T - \int_0^T \dot{\boldsymbol{\lambda}}(t)^\top \cdot \mathbf{w}(t) dt,$$

med användning av randvillkoret $\mathbf{w}(0) = \mathbf{0}$ och genom att påtvinga det naturliga terminalvillkoret $\boldsymbol{\lambda}(T) = \mathbf{0}$ för som upphäver randtermen vid den övre gränsen, erhåller vi

$$\int_0^T [-\dot{\boldsymbol{\lambda}}(t)]^\top \mathbf{w}(t) dt = \int_0^T \left[\left(\frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \right)^\top \boldsymbol{\lambda}(t) + \left(\frac{\partial g}{\partial \tilde{\mathbf{q}}} \right)^\top \right]^\top \mathbf{w}(t) dt.$$

Eftersom funktionen $\mathbf{w}$ är godtycklig måste integranderna överensstämja punktvis, vilket ger det slutgiltiga uttrycket för ekvationerna för det adjunkta tillståndet:

$$\dot{\boldsymbol{\lambda}}(t) = - \left[\left(\frac{\partial \hat{\mathbf{f}}}{\partial \tilde{\mathbf{q}}} \right)^\top \boldsymbol{\lambda}(t) + \left(\frac{\partial g}{\partial \tilde{\mathbf{q}}} \right)^\top \right], \quad \boldsymbol{\lambda}(T) = \mathbf{0}.$$

□

Anmärkning 3.2.3 Medan de adjunkta ekvationerna visar sig vara oberoende av indexet $i = 1, \dots, d$ (det vill säga av dimensionen på parametervektorn $\hat{\boldsymbol{\theta}}$), kräver de primala känslighetsekvationerna att man löser d oberoende kopplade system för mängden $\{\partial_{\hat{\theta}_i} \tilde{\mathbf{q}}(t)\}_{i=1}^d$. Detta ger adjunktmetoden en enorm beräkningsmässig fördel jämfört med den primala metoden när parameterrummet är högdimensionellt ($d \gg 1$).

Teoretisk och empirisk validering

En avgörande fråga som uppstår vid denna punkt är att fastställa om lösningen som tillhandahålls av adjunktmetoden $\boldsymbol{\lambda}(t)$, erhållen genom att lösa den bakåtfatsspridande ODE:n, är matematiskt exakt och tillförlitlig för att vägleda numeriska optimeringsprocesser för $\hat{\boldsymbol{\theta}}$. För att behandla detta lägger vi fram både teoretiska och empiriska valideringsargument som stödjer användningen av det adjunkta tillvägagångssättet.

Exaktheten (bortsett från numeriska trunkeringsfel) hos gradienten för förlustfunk-

tionen, beräknad via adjunktmetoden, vilar på tre grundpelare inom matematisk optimeringsteori:

- **Optimalitetsvillkor:** De adjunkta ekvationerna framträder direkt ur Karush-Kuhn-Tucker-villkoren (KKT) för optimering under kontinuerliga villkor [16]. Vid formuleringen av Lagrange-funktionen så som visas i (3.8), dikterar första ordningens stationaritetsvillkor med avseende på tillståndet $\hat{\mathbf{q}}$ entydigt den adjunkta ODE:n, vilket garanterar att de erhållna gradienterna respekterar de dynamiska villkorens struktur.
- **Dualitet:** Den adjunkta variabeln $\boldsymbol{\lambda}(t)$ besitter en fundamental analytisk tolkning som ett mått på känslighet. Specifikt kvantifierar den hur infinitesimala störningar som introduceras i tillståndsvektorn $\hat{\mathbf{q}}(t)$ utbreder sig längs tidshorisonten och hur de påverkar det slutgiltiga värdet på förlustfunktionalen. Detta dualitetsperspektiv är matematiskt ekvivalent med bakåtladdat läge för automatisk differentiering (*reverse-mode automatic differentiation*) som används inom djupinlärning [5], där gradienter flödar bakåt genom beräkningsgrafer.
- **Konsistens med Pontryagins maximumprincip:** Genom att definiera Hamilton-funktionen associerad med det optimala kontrollproblemet som

$$\mathcal{H}(\hat{\mathbf{q}}, \boldsymbol{\lambda}, \hat{\boldsymbol{\theta}}) = \boldsymbol{\lambda}^\top \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}) + g(\hat{\mathbf{q}}, t),$$

föreskriver Pontryagins princip ekvationen för ko-tillståndet (det adjunkta tillståndet) genom

$$\dot{\boldsymbol{\lambda}}(t) = - \left(\frac{\partial \mathcal{H}}{\partial \hat{\mathbf{q}}} \right)^\top = - \left(\frac{\partial \hat{\mathbf{f}}}{\partial \hat{\mathbf{q}}} \right)^\top \boldsymbol{\lambda}(t) - \left(\frac{\partial g}{\partial \hat{\mathbf{q}}} \right)^\top.$$

Adjunktmetoden återfinner exakt dessa nödvändiga optimalitetsvillkor som typifieras i klassisk optimal kontrollteori [17].

Sammanfattningsvis beräknar adjunktmetoden ko-tillståndet eller den adjunkta variabeln $\boldsymbol{\lambda}(t)$ genom att rigoröst påtvinga första ordningens optimalitetsvillkor för Lagrange-funktionen i en kontinuerlig dynamisk miljö. Dess solida grund i det teoretiska ramverket för Karush-Kuhn-Tucker, dess tolkning utifrån dualitetsteori och dess perfekta konsistens med Pontryagins princip säkerställer att de resulterande gradienterna är exakta inom maskinprecisionens gränser. Kompletterat med empiriska valideringsstrategier i kodfasen (såsom gradientkontroll via ändliga differenser, strikt övervakning av konvergenskurvor och utvärdering av den reducerade modellens fysikaliska rimlighet), utgör adjunktmetoden en högprecisionell och matematiskt robust mekanism för parameteroptimering i dynamiska system.

3.3 Ekvationer för de tre gradienterna

Observera att den adjunkta metoden som används i detta arbete kräver beräkning av följande tre gradienter:

$$\frac{\partial \hat{\mathbf{f}}}{\partial \hat{\mathbf{q}}}, \quad \frac{\partial g}{\partial \hat{\mathbf{q}}}, \quad \text{och} \quad \frac{\partial \hat{\mathbf{f}}}{\partial \hat{\boldsymbol{\theta}}},$$

där

$$\hat{\mathbf{f}} : \mathbb{R}^r \times \mathbb{R}^d \rightarrow \mathbb{R}^r$$

betecknar högerledet av dynamiken för modellen av reducerad ordning (ROM-OpInf) i (2.10), och

$$g : \mathbb{R}^r \times [0, T] \rightarrow \mathbb{R}$$

definierar integranden för förlustfunktionalen ℓ i (3.1). Effektiv beräkning av dessa gradienter är avgörande både för bakåtintegrationen av den adjunkta ekvationen och för utvärderingen av den totala derivatan för den reducerade förlusten $\tilde{\ell}$. Nedan presenteras en detaljerad härledning av de analytiska uttrycken för var och en av dessa gradienter.

3.3.1 $\nabla_{\hat{\mathbf{q}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}})$

Vi börjar med att påminna om definitionen av den dynamiska operatoren:

$$\hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}) = \hat{\mathbf{c}} + \hat{\mathbf{A}}\hat{\mathbf{q}} + \hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) + \hat{\mathbf{B}}\mathbf{u}.$$

För att beräkna derivatan av $\hat{\mathbf{f}}$ med avseende på $\hat{\mathbf{q}}$, betraktar vi Gâteaux-derivatan i riktningen av en godtycklig vektor $\mathbf{v} \in \mathbb{R}^r$:

$$\mathbf{D}_{\hat{\mathbf{q}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}; \mathbf{v}) = \mathbf{D}_{\hat{\mathbf{q}}} \hat{\mathbf{f}}[\mathbf{v}] = \lim_{\varepsilon \rightarrow 0} \frac{\hat{\mathbf{f}}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}}) - \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}})}{\varepsilon} = \frac{d}{d\varepsilon} [\hat{\mathbf{f}}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}})]_{\varepsilon=0}.$$

Genom att utveckla uttrycket erhåller vi:

$$\hat{\mathbf{f}}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}}) = \hat{\mathbf{c}} + \hat{\mathbf{A}}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}) + \hat{\mathbf{H}}((\hat{\mathbf{q}} + \varepsilon \mathbf{v}) \otimes (\hat{\mathbf{q}} + \varepsilon \mathbf{v})) + \hat{\mathbf{B}}\mathbf{u}.$$

Den kvadratiske termen utvecklas på följande sätt:

$$(\hat{\mathbf{q}} + \varepsilon \mathbf{v}) \otimes (\hat{\mathbf{q}} + \varepsilon \mathbf{v}) = \hat{\mathbf{q}} \otimes \hat{\mathbf{q}} + \varepsilon(\hat{\mathbf{q}} \otimes \mathbf{v} + \mathbf{v} \otimes \hat{\mathbf{q}}) + \varepsilon^2(\mathbf{v} \otimes \mathbf{v}).$$

Genom att sätta in denna utveckling i uttrycket för $\hat{\mathbf{f}}$, härleds att:

$$\hat{\mathbf{f}}(\hat{\mathbf{q}} + \varepsilon \mathbf{v}, \hat{\boldsymbol{\theta}}) = \hat{\mathbf{c}} + \hat{\mathbf{A}}\hat{\mathbf{q}} + \varepsilon \hat{\mathbf{A}}\mathbf{v} + \hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) + \varepsilon \hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \mathbf{v} + \mathbf{v} \otimes \hat{\mathbf{q}}) + \hat{\mathbf{B}}\mathbf{u} + \mathcal{O}(\varepsilon^2).$$

Differentiering med avseende på ε och utvärdering vid $\varepsilon = 0$ ger:

$$\mathbf{D}_{\hat{\mathbf{q}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}; \mathbf{v}) = \hat{\mathbf{A}}\mathbf{v} + 2\hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \mathbf{v}),$$

där vi har använt det faktum att $\hat{\mathbf{H}}$ är Kronecker-symmetrisk, det vill säga $\hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \mathbf{v}) = \hat{\mathbf{H}}(\mathbf{v} \otimes \hat{\mathbf{q}})$. Genom att likställa riktningsderivatorna med deras respektive inre produkter erhålls:

$$(\hat{\mathbf{A}} + 2\hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \mathbf{I}_r)) \mathbf{v} = \mathbf{D}_{\hat{\mathbf{q}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}; \mathbf{v}) = (\nabla_{\hat{\mathbf{q}}} \hat{\mathbf{f}})^{\top} \mathbf{v},$$

där $\mathbf{I}_r$ betecknar identitetsmatrisen av storlek r . Gradienten ges därför av:

$$\nabla_{\hat{\mathbf{q}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}) = \hat{\mathbf{A}}^{\top} + (2\hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \mathbf{I}_r))^{\top} = \hat{\mathbf{A}}^{\top} + 2\mathbf{M}(\hat{\mathbf{q}}) \in \mathbb{R}^{r \times r}, \quad (3.15)$$

där vi definierar den asymmetriska matrisen $\mathbf{M}(\hat{\mathbf{q}}) := (\hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \mathbf{I}_r))^{\top} \in \mathbb{R}^{r \times r}$.

Det är värt att notera att detta resultat är helt konsistent med den analytiska formulering som presenterades i det första bevisexemplet rörande den kvadratiske strukturen i (3.14).

3.3.2 $\nabla_{\hat{\mathbf{q}}} g(\hat{\mathbf{q}}, t)$

Per definition ges integranden i förlustfunktionen av

$$g(\hat{\mathbf{q}}(t), t) = \left\| \hat{\mathbf{q}}(t) - \hat{\mathbf{q}}_{\text{true}}(t) \right\|_2^2,$$

där $\hat{\mathbf{q}}(t)$ representerar den predikterade tillståndsvektorn vid tiden t , och $\hat{\mathbf{q}}_{\text{true}}(t)$ är motsvarande tillståndsvektor för sanna data vid samma tidpunkt. Av analytiska bekvämlighetsskäl introducerar vi residualvektorn:

$$\mathbf{r}(\hat{\mathbf{q}}(t), t) := \hat{\mathbf{q}}(t) - \hat{\mathbf{q}}_{\text{true}}(t).$$

På detta sätt uttrycks Gâteaux-derivatan av g i riktningen $\mathbf{v} \in \mathbb{R}^r$ som

$$\begin{aligned} \mathbf{D}_{\hat{\mathbf{q}}} g[\mathbf{v}] &= \frac{d}{d\varepsilon} g(\hat{\mathbf{q}}(t) + \varepsilon \mathbf{v}, t) \Big|_{\varepsilon=0} = \frac{d}{d\varepsilon} \left(\left\| \hat{\mathbf{q}}(t) + \varepsilon \mathbf{v} - \hat{\mathbf{q}}_{\text{true}}(t) \right\|_2^2 \right) \Big|_{\varepsilon=0} \\ &= \frac{d}{d\varepsilon} \left(\left\| \mathbf{r}(\hat{\mathbf{q}}(t), t) + \varepsilon \mathbf{v} \right\|_2^2 \right) \Big|_{\varepsilon=0} \\ &= 2 (\mathbf{r}(\hat{\mathbf{q}}(t), t) + \varepsilon \mathbf{v})^{\top} \mathbf{v} \Big|_{\varepsilon=0} \\ &= 2 (\mathbf{r}(\hat{\mathbf{q}}(t), t))^{\top} \mathbf{v}, \end{aligned}$$

där likheten för derivatan av normen härleds från differentialidentiteten:

$$\frac{d}{d\varepsilon} \|\mathbf{r} + \varepsilon \mathbf{v}\|^2 = \frac{d}{d\varepsilon} [(\mathbf{r} + \varepsilon \mathbf{v})^\top (\mathbf{r} + \varepsilon \mathbf{v})] = 2(\mathbf{r} + \varepsilon \mathbf{v})^\top \mathbf{v}.$$

Följaktligen identifierar vi direkt uttrycket för den slutgiltiga gradienten:

$$\nabla_{\hat{\mathbf{q}}(t)} g(\hat{\mathbf{q}}(t), t) = 2(\hat{\mathbf{q}}(t) - \hat{\mathbf{q}}_{\text{true}}(t)) \in \mathbb{R}^r. \quad (3.16)$$

3.3.3 $\nabla_{\hat{\theta}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\theta})$

Låt oss komma ihåg att den globala parametervektorn, i enlighet med Definition 3.1.1, definieras strukturerad som

$$\hat{\theta} = \left[\underbrace{\hat{\mathbf{c}}}_{\in \mathbb{R}^r}, \underbrace{\text{vec}(\hat{\mathbf{A}})}_{\in \mathbb{R}^{r^2}}, \underbrace{\text{vec}(\hat{\mathbf{H}})}_{\in \mathbb{R}^{r^3}}, \underbrace{\text{vec}(\hat{\mathbf{B}})}_{\in \mathbb{R}^{rm}} \right] \in \mathbb{R}^d, \quad d = r + r^2 + r^3 + rm.$$

För att kunna beräkna varje matrisblock oberoende av varandra, delar vi upp gradienten i fyra strukturella underblock:

$$\nabla_{\hat{\theta}} \hat{\mathbf{f}} = \begin{bmatrix} \nabla_{\hat{\mathbf{c}}} \hat{\mathbf{f}} \\ \nabla_{\hat{\mathbf{A}}} \hat{\mathbf{f}} \\ \nabla_{\hat{\mathbf{H}}} \hat{\mathbf{f}} \\ \nabla_{\hat{\mathbf{B}}} \hat{\mathbf{f}} \end{bmatrix} :$$

(i) Gradient med avseende på $\hat{\mathbf{c}}$.

För varje riktning $\mathbf{v}_{\hat{\mathbf{c}}} \in \mathbb{R}^r$,

$$\mathbf{D}_{\hat{\mathbf{c}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\theta}; \mathbf{v}_{\hat{\mathbf{c}}}) = \frac{d}{d\varepsilon} \left(\hat{\mathbf{c}} + \varepsilon \mathbf{v}_{\hat{\mathbf{c}}} \right) \Big|_{\varepsilon=0} = \mathbf{v}_{\hat{\mathbf{c}}} = \mathbf{I}_r \mathbf{v}_{\hat{\mathbf{c}}} = (\nabla_{\hat{\mathbf{c}}} \hat{\mathbf{f}})^\top \mathbf{v}_{\hat{\mathbf{c}}},$$

därför följer,

$$\nabla_{\hat{\mathbf{c}}} \hat{\mathbf{f}} = \mathbf{I}_r \in \mathbb{R}^{r \times r}.$$

(ii) Gradient med avseende på $\hat{\mathbf{A}}$.

För varje matris $\mathbf{V}_A \in \mathbb{R}^{r \times r}$ med $\tilde{\mathbf{v}}_A = \text{vec}(\mathbf{V}_A) \in \mathbb{R}^{r^2}$,

$$\mathbf{D}_{\hat{\mathbf{A}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\theta}; \mathbf{V}_A) = \frac{d}{d\varepsilon} \left((\hat{\mathbf{A}} + \varepsilon \mathbf{V}_A) \hat{\mathbf{q}} \right) \Big|_{\varepsilon=0} = \mathbf{V}_A \hat{\mathbf{q}} = (\hat{\mathbf{q}} \otimes \mathbf{I}_r)^\top \tilde{\mathbf{v}}_A = (\nabla_{\hat{\mathbf{A}}} \hat{\mathbf{f}})^\top \tilde{\mathbf{v}}_A, Fl$$

från vilket det härleds att

$$\nabla_{\hat{\mathbf{A}}} \hat{\mathbf{f}} = \hat{\mathbf{q}} \otimes \mathbf{I}_r \in \mathbb{R}^{r^2 \times r}.$$

(iii) Gradient med avseende på $\hat{\mathbf{H}}$.

För varje konfiguration $\mathbf{V}_H \in \mathbb{R}^{r \times r^2}$ med $\tilde{\mathbf{v}}_H = \text{vec}(\mathbf{V}_H) \in \mathbb{R}^{r^3}$,

$$\mathbf{D}_{\hat{\mathbf{H}}} \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}; \mathbf{V}_H) = \left. \frac{d}{d\varepsilon} \left((\hat{\mathbf{H}} + \varepsilon \mathbf{V}_H) (\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) \right) \right|_{\varepsilon=0} = \mathbf{V}_H (\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) = ((\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) \otimes \mathbf{I}_r)^\top \tilde{\mathbf{v}}_H = (\nabla_{\hat{\mathbf{H}}} \hat{\mathbf{f}})^\top \tilde{\mathbf{v}}_H,$$

vilket ger

$$\nabla_{\hat{\mathbf{H}}} \hat{\mathbf{f}} = (\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) \otimes \mathbf{I}_r \in \mathbb{R}^{r^3 \times r}.$$

(iv) Gradient med avseende på $\hat{\mathbf{B}}$.

På analogt sätt visas att

$$\nabla_{\hat{\mathbf{B}}} \hat{\mathbf{f}} = \mathbf{u} \otimes \mathbf{I}_r \in \mathbb{R}^{rm \times r}.$$

För att underlätta den efterföljande algoritmiska implementeringen uttrycker vi gradienterna med avseende på $\hat{\boldsymbol{\theta}}$ på deras transponerade form, så att de kopplas samman med förlustfunktionalens formulering för adjunktmetoden beskriven i (3.13). Genom att sammanföra de fyra transponerade blocken blir det slutgiltiga uttrycket för gradientoperatören således

$$\nabla_{\hat{\boldsymbol{\theta}}}^\top \hat{\mathbf{f}}(\hat{\mathbf{q}}, \hat{\boldsymbol{\theta}}) = [\mathbf{I}_r, \hat{\mathbf{q}}^\top \otimes \mathbf{I}_r, (\hat{\mathbf{q}} \otimes \hat{\mathbf{q}})^\top \otimes \mathbf{I}_r, \mathbf{u}^\top \otimes \mathbf{I}_r] \in \mathbb{R}^{r \times d}. \quad (3.17)$$

3.4 Gradientgradientmetod för parameteroptimering

När gradienten för den reducerade förlustfunktionalen $\tilde{\ell}(\hat{\boldsymbol{\theta}})$ har erhållits via adjunktmetoden, fortsätter vi med att minimera $\tilde{\ell}$ över parameterrummet $\hat{\boldsymbol{\theta}} \in \mathbb{R}^d$ genom att använda gradientmetoden (Gradient Descent, GD) [18, 19]. Specifikt genererar vi, utifrån en initial parametervektor $\hat{\boldsymbol{\theta}}^0$, en sekvens $\{\hat{\boldsymbol{\theta}}^j\}_{j \geq 0}$ genom iterativ uppdatering av parametrarna i den negativa gradientriktningen (riktningen för brantaste nedgång):

$$\hat{\boldsymbol{\theta}}^{j+1} = \hat{\boldsymbol{\theta}}^j - \eta_j \nabla \tilde{\ell}(\hat{\boldsymbol{\theta}}^j), \quad j = 0, 1, 2, \dots \quad (3.18)$$

där

- $\nabla \tilde{\ell}(\hat{\boldsymbol{\theta}}^j)$ representerar den exakta gradienten utvärderad via de adjunkta ekvationerna,
- $\eta_j > 0$ är steglängden (inlärningshastigheten) i iterationen j .

Proceduren avbryts så snart ett konvergensbaserat stoppkriterium är uppfyllt. Ett vanligt stoppvillkor ges av

$$\|\nabla \tilde{\ell}(\hat{\boldsymbol{\theta}}^j)\|_2 \leq \epsilon, \quad (3.19)$$

för en föreskriven tolerans $\epsilon > 0$. Under ett lämpligt val av sekvensen $\{\eta_j\}$ och under

antagande om regularitetshypoteser på $\tilde{\ell}$, konvergerar iterationerna $\hat{\boldsymbol{\theta}}^j$ mot en stationär punkt i systemet.

Val av inlärningshastighet och konvergensöverbälganden

Valet av η_j påverkar konvergensbeteendet direkt. Användningen av en konstant steglängd $\eta_j = \eta$ är utbredd, men kräver en noggrann finjustering för att balansera konvergenshastighet och numerisk stabilitet.

Nedan introduceras två fundamentala definitioner som används i den numeriska konvergensanalysen av gradientmetoden [20].

Definition 3.4.1 (L -slät funktion) En differentierbar funktion $\mathcal{J} : \mathbb{R}^p \rightarrow \mathbb{R}$ sägs vara L -slät om det existerar en Lipschitz-konstant $L > 0$ sådan att, för varje par av vektorer $\boldsymbol{\omega}, \tilde{\boldsymbol{\omega}} \in \mathbb{R}^p$,

$$\|\nabla \mathcal{J}(\boldsymbol{\omega}) - \nabla \mathcal{J}(\tilde{\boldsymbol{\omega}})\|_2 \leq L \|\boldsymbol{\omega} - \tilde{\boldsymbol{\omega}}\|_2. \quad (3.20)$$

Ekvation (3.20) fastställer att gradientoperatoren för $\mathcal{J}$ är Lipschitz-kontinuerlig med konstanten L .

Definition 3.4.2 (μ -starkt konvex funktion) En funktion $\mathcal{J} : \mathbb{R}^p \rightarrow \mathbb{R}$ sägs vara μ -starkt konvex om det existerar en krökningskonstant $\mu > 0$ sådan att, för varje par av vektorer $\boldsymbol{\omega}, \tilde{\boldsymbol{\omega}} \in \mathbb{R}^p$,

$$\mathcal{J}(\tilde{\boldsymbol{\omega}}) \geq \mathcal{J}(\boldsymbol{\omega}) + \nabla \mathcal{J}(\boldsymbol{\omega})^\top (\tilde{\boldsymbol{\omega}} - \boldsymbol{\omega}) + \frac{\mu}{2} \|\tilde{\boldsymbol{\omega}} - \boldsymbol{\omega}\|_2^2. \quad (3.21)$$

Detta villkor innebär det att funktionen $\mathcal{J}$ har en strikt undre begränsning i sin krökning, vilket garanterar global konvexitet. En ekvivalent karakterisering av stark μ -konvexitet kan formuleras i termer av Hessian-matrisen:

$$\mathcal{J} \text{ är } \mu\text{-starkt konvex} \quad \Leftrightarrow \quad \nabla^2 \mathcal{J}(\boldsymbol{\omega}) \succeq \mu \mathbf{I}, \quad \forall \boldsymbol{\omega} \in \mathbb{R}^p \quad (3.22)$$

där $\nabla^2 \mathcal{J}(\boldsymbol{\omega})$ betecknar Hessianen för $\mathcal{J}$ utvärderad i $\boldsymbol{\omega}$, och $\mu \mathbf{I}$ representerar identitetsmatrisen skalad med faktorn μ . Detta säkerställer att alla egenvärden för Hessianen är minst μ , vilket tryggar en undre gräns för konvexiteten.

Under hypoteserna om L -släthet och stark μ -konvexitet för målfunktionen $\mathcal{J}(\boldsymbol{\omega})$, tillsammans med en begränsad steglängd, konvergerar GD-metoden garanterat mot ett unikt globalt minimum för $\mathcal{J}(\boldsymbol{\omega})$ [20]. Tabell 3.1 sammanfattar konvergensfelshastigheterna för GD under olika villkor för släthet och konvexitet associerade med olika val av steglängd.

För μ -starkt konvexa funktioner $\mathcal{J}$ utmärker sig två essentiella egenskaper som säkerställer ett mycket effektivt optimeringsbeteende:

Villkor	Steglängd (η)	Felhastighet
$\mathcal{J}$ är L -slät	$\frac{1}{L}$	$\mathcal{J}(\omega^j) - \mathcal{J}(\omega^*) \leq \frac{1}{j\eta} \ \omega^0 - \omega^*\ _2^2$
$\mathcal{J}$ är L -slät och μ -starkt konvex	$\frac{1}{L}$	$\ \omega^j - \omega^*\ _2 \leq \left(1 - \frac{\mu}{L}\right)^j \ \omega^0 - \omega^*\ _2$
$\mathcal{J}$ är L -slät och μ -starkt konvex	$\frac{2}{L + \mu}$	$\ \omega^j - \omega^*\ _2 \leq \left(\frac{L - \mu}{L + \mu}\right)^j \ \omega^0 - \omega^*\ _2$
Notera: $\frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}$, där $\kappa := \frac{L}{\mu}$ är konditionstalet för Hessianen $\nabla^2 \mathcal{J}$		

Tabell 3.1: Konvergensfelshastigheter för GD under olika hypoteser om släthet och konvexitet.

- Unicitet hos det absoluta minimat, vilket säkerställer att optimeringsproblemet är välställt.
- Snabb konvergens, vilket garanterar en minst linjär konvergenshastighet med ett exponentiellt avtagande fel.

Inom ramen för Operator Inference läggs frekvent en L^2 -regulariseringsterm till i förlustfunktionen. Det primära syftet med detta är inte att tvinga fram stark konvexitet för den gradientbaserade konvergensanalysen, utan att förbättra den numeriska konditioneringen och algebraiskt stabilisera systemets lösning [9]. Denna regularisering modifierar minstakvadratförlusten genom att straffa Frobeniusnormen för den infererade operatören, vilket leder till följande regulariserade målfunktional:

$$\|\mathbf{D}\widehat{\mathbf{O}}^T - \mathbf{Z}^T\|_F^2 + \xi^2 \|\widehat{\mathbf{O}}^T\|_F^2, \quad (3.23)$$

där $\mathbf{D} \in \mathbb{R}^{k \times d}$ representerar datamatrixen, $\widehat{\mathbf{O}} \in \mathbb{R}^{r \times d}$ är operatormatrixen (parametrar), $\mathbf{Z} \in \mathbb{R}^{r \times k}$ betecknar matrisen för tidsderivator (vänsterledsdata) och $\xi > 0$ representerar regulariseringshyperparametern. Regulariseringstermen främjar att problemet är välställt genom att säkerställa att normalekvationernas matris blir strikt positivt definit, vilket mildrar illakonditionerade problem och förhindrar överanpassning (*overfitting*) vid brusiga träningsdata. Även om detta optimerar den numeriska stabiliteten i lösningen, garanterar det inte direkt snabba konvergenshastigheter för GD, särskilt när värdet på ξ är litet och målfunktionen saknar global stark konvexitet.

Adaptiv steglängd: Armijos linjesökning

Istället för att fixera ett statiskt värde för η_j , implementerar Algoritm 1 en backtracking-procedur för att adaptivt välja värdet på η_j så att Armijos villkor för tillräcklig minskning uppfylls [16]:

Algorithm 1: Armijo Backtracking Linjesökning + Gradientmetod

Steg 1. Initialisering: Välj $\alpha \in (0, 1)$, $\beta \in (0, 1)$ och en initial steglängd $\eta_0 > 0$.

Sätt iterationsräknaren $j = 0$;

Steg 2. Beräkna sökriktning: Utvärdera den exakta gradienten $\mathcal{G}^j = \nabla \tilde{\ell}(\hat{\theta}^j)$;

Steg 3. Backtracking-slinga::

$\eta \leftarrow \eta_0$;

while $\tilde{\ell}(\hat{\theta}^j - \eta \mathcal{G}^j) > \tilde{\ell}(\hat{\theta}^j) - \alpha \eta \|\mathcal{G}^j\|_2^2$ **do**

$\eta \leftarrow \beta \eta$;

end

Steg 4. Uppdatering: Sätt den optimala steglängden $\eta_j = \eta$ och uppdatera parametervektorn genom::

$\hat{\theta}^{j+1} = \hat{\theta}^j - \eta_j \mathcal{G}^j$;

Steg 5. Stoppkriterium: Om $\|\mathcal{G}^{j+1}\|_2 \leq \epsilon$ (eller annat konvergenskriterium) avsluta; i annat fall sätt $j \leftarrow j + 1$ och återgå till Steg 2.;

För stokastiska miljöer eller storskaliga problem föredras ofta varianter såsom stokastisk gradientmetod (SGD) [18] på grund av dess lägre minneskrav och beräkningskostnad per iteration. För datamängder av måttliga dimensioner (som i de numeriska experiment som detaljeras senare) gynnas dock användningen av klassisk gradientmetod tack vare dess högre matematiska precision. Trots att GD-metoden kopplad till Armijos linjesökning applicerad på icke-konvexa problem (såsom den begränsade optimeringsdesign vi adresserar) endast säkerställer konvergens mot någon stationär punkt, utför vi i vår metodik en varmstart (*warm-start*) av GD-algoritmen. För detta ändamål tar vi de operatorer som erhållits via den algebraiska regressionen från Operator Inference i (2.12) som initiallösning. Eftersom denna initiala approximation redan befinner sig i närheten av ett minimum av hög kvalitet, konvergerar GD-processen mycket snabbt och minskar drastiskt sannolikheten för att fastna i suboptimala stationära punkter.

3.5 Algoritm för adjunktmetoden

Nedan detaljeras den fullständiga träningsalgoritmen baserad på det adjunkta tillståndet, vilken integrerar stegen för dataförbehandling, reducerad ordningsmodellering och parameterraffinering via gradientoptimering. Algoritm 2 sammanfattar det arbetsflöde som härletts i de föregående avsnitten: efter att ha samlat in och förbehandlat data från högupplösningssmodellen beräknas en initial parameteruppskattning via Operator Inference [9], för att sedan iterativt lösa det framåtriktade och det adjunkta systemet, beräkna de exakta gradienterna och exekvera gradientmetoden med backtracking tills operatorernas konvergens har uppnåtts.

Algorithm 2: Adjunktmetod för parameterträning

Input: Ögonblicksbilder (*snapshots*) från den fullständiga modellen $\mathbf{Q}, \mathbf{U}$;
backtracking-parametrar (α, β, η_0) ; konvergenstolerans ϵ ; träningsstidsintervall $[t_1, t_k]$; maximalt antal iterationer j_{max} .

Output: Optimerade parametrar för den reducerade modellen $\hat{\boldsymbol{\theta}}^*$.

Steg 1. Datainsamling och förbehandling: Samla in matriserna med ögonblicksbilder $\mathbf{Q} = [\mathbf{q}_{t_1}, \dots, \mathbf{q}_{t_k}]$, $\mathbf{U} = [\mathbf{u}_{t_1}, \dots, \mathbf{u}_{t_k}]$. [Valfritt] Utför skalnings-, centrerings- eller icke-linjära transformationer (*lifting*);

Steg 2. Dimensionsreduktion: Beräkna den ortonormala POD-basen $\mathbf{V}_r$ (via kriterium för ackumulerad energi eller genom att fixera en konstant ROM-dimension r). Projektera systemets tillstånd: $\hat{\mathbf{Q}} \approx \mathbf{V}_r^T \mathbf{Q}$;

Steg 3. Initial parameteruppskattning: Lös det linjära regressionsproblemet för OpInf med hjälp av $\hat{\mathbf{Q}}$ för att erhålla de initiala operatorerna $\hat{\boldsymbol{\theta}}_{\text{OpInf}}^*$;

Steg 4. Gradientmetodens slinga: Initialisera räknaren $j = 0$, sätt de initiala parametrarna $\hat{\boldsymbol{\theta}}^0 = \langle b \rangle \hat{\boldsymbol{\theta}}_{\text{OpInf}}^* / \langle b \rangle$ och definiera gränserna för steglängden. Exekvera iterativt::

4.1. **Lösning av den framåtriktade modellen (*forward*):** Beräkna den reducerade banan $\tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}^j)$ genom att lösa EDO:n av reducerad ordning;

4.2. **Beräkning av tillståndsresidual:** Utvärdera den kontinuerliga residualvektorn $\mathbf{r}(\tilde{\mathbf{q}}, t) := \tilde{\mathbf{q}}(t, \hat{\boldsymbol{\theta}}^j) - \hat{\mathbf{q}}_{\text{true}}(t)$;

4.3. **Lösning av den adjunkta modellen:** Integrera EDO:n för det adjunkta tillståndet (3.12) bakåt i tiden för att bestämma $\boldsymbol{\lambda}(t)$, genom att applicera de relationer som ges i (3.15) och (3.16);


4.4. **Sammanställning av gradienten:** Konstruera den globala gradientvektorn $\nabla \tilde{\ell}(\hat{\boldsymbol{\theta}}^j)$ enligt ekvation (3.13) med hjälp av den blockstruktur som härleddes i (3.17);

4.5. **Armijos linjesökning:** Bestäm den adaptiva steglängden η_j via backtracking genom att använda schemat i Algoritm 1;

4.6. **Parameteruppdatering:** Uppdatera den reducerade modellens operatorer genom: $\hat{\boldsymbol{\theta}}^{j+1} = \hat{\boldsymbol{\theta}}^j - \eta_j \nabla \tilde{\ell}(\hat{\boldsymbol{\theta}}^j)$;

4.7. **Utvärdering av stoppkriterier:** Verifiera systemets konvergens. Om $\|\nabla \tilde{\ell}(\hat{\boldsymbol{\theta}}^{j+1})\|_2 \leq \epsilon$ eller om $j = j_{max}$, avsluta slingan; i annat fall sätt $j \leftarrow j + 1$ och upprepa från steg 4.1;

Steg 5. Returnera den slutgiltiga vektorn med optimerade operatorer $\hat{\boldsymbol{\theta}}^* = \hat{\boldsymbol{\theta}}^{j+1}$;



Figur 3.1: Schema över processen för inferens av reducerade ordningsmodeller (ROM); det klassiska algebraiska flödet för OpInf (övre grenen) och raffinering baserad på den dynamiska adjunktmetoden (nedre grenen).

NUMERISKA EXPERIMENT

I detta kapitel utvärderar vi den föreslagna träningsmetoden baserad på det adjungerade tillståndet på två kanoniska icke-linjära PDE:er: den 1D-viskösa Burgers ekvation och den 2D-Fisher-KPP-ekvationen. Dessa testfall valdes för att utmana ramverket för reducerad ordningsmodellering på olika sätt: Burgers ekvation med en liten viskositetsparameter $\nu = 0.01$ genererar branta gradienter och icke-linjära advektions-diffusionsinteraktioner, medan Fisher-KPP-ekvationen uppvisar en reaktions-diffusionsdynamik i två rumsliga dimensioner.

För varje modell jämför vi den adjungerade metoden med standardmetoden för OpInf [9] under två störningsscenarier:

- (i) reducering av den temporala samplingsdensiteten för träningsögonblicksbilderna (*snapshots*), och
- (ii) addering av syntetiskt brus till datan.

Vår hypotes är att eftersom den adjungerade metoden beräknar exakta gradienter av förlustfunktionalen, kommer den att ge mer robusta och noggranna parameterestimater än OpInf (som är beroende av finita differensapproximationer av tidsderivatorna), särskilt när träningsdatan är brusig eller gles samplad.

Alla experiment delar en gemensam numerisk konfiguration. Standardlösningarna för OpInf erhålls via Python-paketet `opinf` som tillhandahålls av Willcox Research Group [9]. Vi konstruerar en POD-bas $\mathbf{V}_r$ som fångar upp minst 99.9% av ögonblicksbildernas energi ($\kappa_r \geq 0.999$). I OpInf-regressionen använder vi finita differensscheman av upp till andra och sjätte ordningen ('ord2', 'ord6') för och approximerar $\dot{\mathbf{Q}}$. Tidsintegraler utvärderas med den ackumulerade trapetsregeln från '`scipy.integrate`' [21], och de adjungerade ekvationerna löses bakåt i tiden med ett implicit Euler-schema. Parametrarna för Armijos sökning längs linjen med backtracking fixeras till $\alpha = 10^{-4}$, $\beta = 0.5$, $\eta_0 = 10^{-3}$, och gradientnedstigningen avslutas när ett toleransvärde på $\epsilon = 10^{-8}$ uppnås eller efter

1000 iterationer (se implementeringen av Algoritm 2 i Bilaga B.3). Slutligen använder vi de optimerade parametrarna $\hat{\boldsymbol{\theta}}^*$ för att predicera nya trajektorier genom att lösa den inlärda ROM-modellen med lösaren `'solve_ivp(method=BDF)'` från SciPy [22].

4.1 Viskös Burgers ekvation

Datagenerering (Snapshots)

För att generera datamängden för modellreduktion via operatorinferens (OpInf) löser vi den endimensionella viskösa Burgers ekvation (för Python-implementeringen, se Bilaga B.1):

$$q_t + q q_x = \nu q_{xx}, \quad x \in [0, 1], \quad t \in [0, T], \quad \nu = 0.01,$$

underkastad homogena Dirichlet-randvillkor

$$q(t, 0) = q(t, 1) = 0,$$

och initialvillkoret som en sinusvåg

$$q(x, 0) = \sin(2\pi x).$$

Därefter används följande diskretiseringsschema med finita differenser:

- Tidsnät: sluttid $T = 1$, antal tidssteg $M = 9999$, vilket ger $\Delta t = T/M$.
- Rumsnät: domänlängd $L = 1$, $N = 2^7$ inre noder, $\Delta x = L/(N + 1)$; vi numrerar nätpunkterna som $x_j = j \Delta x$ för $j = 0, \dots, N + 1$.
- Konvektionsterm (Lax-Wendroff): låt oss beteckna med $\mathbf{w}^m = \mathbf{LW}(\mathbf{q}^m) \in \mathbb{R}^{N+2}$ Lax-Wendroff-uppdateringen av tillståndet $\mathbf{q}^m$. Dess j -te komponent ges av

$$w_j^m = q_j^m - \frac{\Delta t}{2 \Delta x} q_j^m (q_{j+1}^m - q_{j-1}^m) + \frac{\Delta t^2}{2 \Delta x^2} q_j^m \left[\frac{1}{2} (q_{j+1}^m - q_{j-1}^m)^2 + q_j^m (q_{j+1}^m - 2q_j^m + q_{j-1}^m) \right].$$




De homogena Dirichlet-randvillkoren påtvingas genom att sätta $w_0^m = w_{N+1}^m = 0$.

- Diffusionsterm (Trapetsregeln):

$$\left(\mathbf{I} - \frac{\nu \Delta t}{2} \mathbf{T}_{\Delta x} \right) \mathbf{q}^{m+1} = \mathbf{LW}(\mathbf{q}^m) + \frac{\nu \Delta t}{2} \mathbf{T}_{\Delta x} \mathbf{q}^m,$$

där $\mathbf{T}_{\Delta x} = \text{tridiag}\{1, -2, 1\}$ är standardmatrisen för andraordningens differenser med nollskilda Dirichlet-randvillkor.


Genom att stapla lösningen av detta glesa linjära ekvationssystem för varje tidpunkt erhålls ögonblicksbildsmatrisen $\mathbf{Q}_{\text{FOM}} = \mathbf{Q} \in \mathbb{R}^{(N+2) \times (M+1)}$, som vi använder för modellreduktion. I Figur 4.1 visas tre vyer av denna dynamik.

(a) Profiler $q(x, t_k)$ vid valda tidpunkter t_k .(b) 3D-yta av $q(x, t)$ för $\nu = 0.01$.(c) Tids-rumskontur av $q(x, t)$.**Figur 4.1:** Dynamik för den viskösa Burgers ekvation som används för datagenerering.

Utifrån Burgers ögonblicksbildsmatrix $\mathbf{Q}$ tillämpar vi först Algoritm 2 för att erhålla den optimala parametervektorn $\hat{\boldsymbol{\theta}}^*$, varvid ögonblicksbilderna i tidsintervallet $t \in [0, 0.5]$ används som träningsdata. Därefter använder vi dessa inlärda parametrar för och predicera systemets evolution i det återstående intervallet $t \in (0.5, 1.0]$ genom integration av den reducerade dynamiska modellen med SciPy:s implicita BDF-lösare `solve_ivp` [22]. I den första testomgången reducerar vi systematiskt antalet ögonblicksbilder till 100% (10 000 punkter), 10% (1 000 punkter), 1% (100 punkter) och 0.2% (20 punkter) av det ursprungliga tidsnätet för att simulera gles data. I varje scenario estimerar vi OpInf-parametrarna med finita differenser av både andra ordningen ('ord2') och sjätte ordningen ('ord6'), med en tillämpad L^2 -regulariseringsvikt på $\xi = 10^{-2}$.

Figur 4.2 visar, för varje samplingsnivå, de faktiska reducerade tillstånden $\hat{\mathbf{q}}_{\text{true}}$ (helledragen linje) mot de predicerade trajektorierna $\hat{\mathbf{q}}_{\text{pred}}$ (streckad linje) för både OpInf-modellen och modellen tränad med den adjungerade metoden. Här motsvarar varje kurva $\hat{q}_{i,\text{true}}(t)$ den i -te raden (upp till dimensionen r) i den reducerade ögonblicksbildsmatrisen $\hat{\mathbf{Q}}$, och $\hat{q}_{i,\text{pred}}(t)$ betecknar dess motsvarande predicerade trajektorievärde vid tiden t . Även under extremt gles sampling genererar den adjungerade metoden prediktioner som är visuellt oskiljaktiga från OpInf, vilket påvisar dess motståndskraft i frånvaro av brus.

Reducering av datadensitet




Figur 4.2: Resultat av reduceringen av datadensitet för det syntetiska experimentet med Burgers ekvation.

För att kvantifiera inverkan av träningsdatans gleshet beräknar vi prediktionsfelet i testregionen $t \in [0.5, 1]$ för varje samplingsdensitet. Specifikt löser vi begynnelsevärdesproblemet för ROM-OpInf med de inlärda operatorerna och jämför trajektorierna mot de faktiska reducerade tillstånden för varje samplingsnivå (100%, 10%, 1% respektive 0.2%):

$$\|\hat{\mathbf{q}}_{\text{true}}(t) - \hat{\mathbf{q}}_{\text{pred}}(t)\|_2, \quad t \in [0.5, 1].$$

Figur 4.3 jämför felkurvorna för OpInf och den adjungerade metoden över alla samplingsnivåer. Den adjungerade metoden ger fel som är likartade eller till och med lägre än de som erhålls när schemat av sjätte ordningen används, vilket bekräftar dess noggrannhet i att fånga information om tidsderivatan under begränsad data.




Figur 4.3: Prediktionsfel mot tid för varje körning av datadensitetsreducering i experimentet med Burgers ekvation.


Figur 4.4 visar det relativa felet

$$\frac{\|\hat{\mathbf{q}}_{\text{true}}(t) - \hat{\mathbf{q}}_{\text{pred}}(t)\|_2}{\|\hat{\mathbf{q}}_{\text{true}}(t)\|_2}, \quad t \in [0, 1],$$


som en funktion av ROM-dimensionen r . Återigen motsvarar varje delfigur en av de fyra samplingsdensiteterna. Båda metoderna uppvisar det förväntade avtagandet i relativt fel i takt med att r ökar. Men i fallet med mest extrem gleshet (0.2%) uppnår den modell som tränats med den adjungerade metoden marginellt mindre fel, vilket tyder på att den kan konstruera mer effektiva reducerade baser när informationen från ögonblicksbilderna är knapphändig.




(a) 100% av datan.



(b) 10% av datan.




(c) 1% av datan.



(d) 0.2% av datan.

Figur 4.4: Relativt fel mot r för varje körning av datadensitetsreducering i experimentet med Burgers ekvation.

Brusstörning




Figur 4.5: Simuleringar av brusstörningar för det syntetiska experimentet med Burgers ekvation.

För den andra testomgången, i syfte att utvärdera robustheten under imperfekt data, korrumpierar vi den fullständiga modellens ögonblicksbilder med additivt gausstiskt brus. Specifikt drar vi

$$\text{fel} \sim \mathcal{N}(0, \sigma^2), \quad \sigma = \frac{\text{pct}}{100} \max_{1 \leq j \leq k} \|\mathbf{q}(t_j)\|_2,$$


för brusnivåer på 1%, 5%, 10% och 20%. Varje brusig datamängd används för att träna både OpInf-modellen och den adjungerade modellen över $t \in [0, 0.5]$, varvid prediktionerna utförs på $[0.5, 1]$. Figur 4.5 visualiserar de faktiska reducerade tillstånden (punkter och hel-dragen linje) mot de tränade prediktionerna (streckad linje) för båda metoderna vid varje brusnivå. Allteftersom bruset ökar, följer den ROM som tränats via den adjungerade metoden de faktiska trajektorierna på ett konsistent mer noggrant sätt än OpInf, vilket belyser den överlägsna troheten hos dess gradient i närvaro av datakorruption.

Figur 4.6 visar det tidsberoende prediktionsfelet, så som det definierades tidigare, för varje brusnivå. Även om alla metoder degraderas när bruset växer, bibehåller den adjungerade metoden lägre fel över tid än båda OpInf-tillvägagångssätten.



Figur 4.6: Prediktionsfel mot tid för varje körning av brusnivå i experimentet med Burgers ekvation.

För och ytterligare kvantifiera modelleffektiviteten visar Figur 4.7 det relativa felet som funktion av modellens dimension r . För varje brusnivå observerar vi att den ROM som tränats med den adjungerade metoden uppnår bättre noggrannhet för samma antal moder än båda OpInf-metoderna, särskilt vid 5%, 10% och 20% brus. Detta bekräftar att den adjungerade gradienten ger mer informativa parameteruppdateringar även när träningsdatan är korrumperad.



Figur 4.7: Relativt fel mot r för varje körning av brusstörning i experimentet med Burgers ekvation.

4.2 Fisher-KPP-ekvationen

Datagenerering (Snapshots)

För detta andra syntetiska experiment genererar vi träningsdatan (se koden i Bilaga B.2) genom att numeriskt lösa den tvådimensionella Fisher-KPP-ekvationen,

$$q_t = \mathfrak{D} (q_{xx} + q_{yy}) + \rho q (1 - q), \quad (x, y) \in [0, L_x] \times [0, L_y], \quad t \in [0, T],$$

med homogena Neumann-randvillkor (nollflöde)

$$\frac{\partial q}{\partial n} \Big|_{\partial\Omega} = 0,$$

och ett gaussiskt initialvillkor centrerat i domänen:

$$q(x, y, 0) = \exp\left(-10[(x - L_x/2)^2 + (y - L_y/2)^2]\right).$$

Följande nät och parametrar beaktas:

- Domänstorlekar: $L_x = L_y = 10$.
- Nät: $N_x = N_y = 100$ punkter i varje riktning, $\Delta x = L_x/(N_x - 1)$, $\Delta y = L_y/(N_y - 1)$.
- Tidssteg: sluttid $T = 5$, $\Delta t = 0.005$, $N_t = T/\Delta t = 1000$.
- Modellparametrar: diffusionskoefficient $\mathfrak{D} = 0.1$, logistisk tillväxthastighet $\rho = 1.0$.

Därefter tillämpas en finit differensmetod för de rumsliga diskretiseringarna:

- För x -dimensionen konstruerar vi en 1D-matris för andraordningens differenser $\mathbf{L}_x^{1D} \in \mathbb{R}^{N_x \times N_x}$ med Neumann-randvillkor genom

$$(\mathbf{L}_x^{1D})_{jj} = -\frac{2}{\Delta x^2}, \quad (\mathbf{L}_x^{1D})_{j,j\pm 1} = \frac{1}{\Delta x^2}, \quad (\mathbf{L}_x^{1D})_{0,1} = (\mathbf{L}_x^{1D})_{N_x-1,N_x-2} = \frac{2}{\Delta x^2}.$$

- På liknande sätt definierar vi $\mathbf{L}_y^{1D} \in \mathbb{R}^{N_y \times N_y}$ över y -nätet.
- Båda uttrycken kombineras för att bilda en fullständig 2D-Laplaceoperator via Kroeckersummor

$$\mathbf{L} = \mathbf{I}_{N_y} \otimes \mathbf{L}_x^{1D} + \mathbf{L}_y^{1D} \otimes \mathbf{I}_{N_x} \in \mathbb{R}^{(N_x N_y) \times (N_x N_y)}.$$

För tidsstegsschemat använder vi ett semi-implicit Crank-Nicolson-steg för diffusionen och ett explicit Euler-steg för reaktionstermen:

$$\frac{\mathbf{q}^{m+1} - \mathbf{q}^m}{\Delta t} = \frac{\mathfrak{D}}{2} \mathbf{L}(\mathbf{q}^{m+1} + \mathbf{q}^m) + \rho \mathbf{q}^m \circ (\mathbf{1} - \mathbf{q}^m),$$

där $\circ$ betecknar Hadamardprodukten.


Genom att definiera,

$$\alpha := \frac{\mathfrak{D} \Delta t}{2}, \quad \mathcal{A} := \mathbf{I} - \alpha \mathbf{L}, \quad \mathcal{B} := \mathbf{I} + \alpha \mathbf{L},$$


så gäller i varje tidssteg att

$\mathcal{A} \mathbf{q}^{m+1} = \mathcal{B} \mathbf{q}^m + \Delta t \rho \mathbf{q}^m \circ (\mathbf{1} - \mathbf{q}^m)$. Genom att lösa detta glesa linjära system erhåller vi den önskade tillståndslösningen vid varje tidssteg, vilken vi använder för att konstruera ögonblicksbildsmatrisen $\mathbf{Q} \in \mathbb{R}^{(N_x N_y) \times N_t}$.


Visualiseringen av dynamiken för Fisher-KPP-ekvationen visas i Figur 4.8.



(a) 3D-yta av $q(x, y, t)$ för $\mathfrak{D} = 0.1$ och $\rho = 1$.




(b) Profiler för $q(x, y, t)$ för olika t_k .



(c) Tids-rumskontur av $q(x, y, t)$ vid $t = 5$.

Figur 4.8: Dynamik för FKPP-ekvationen som används för datagenerering.

Brusstörning




Figur 4.9: Simuleringar av brusstörningar för det syntetiska experimentet med FKPP-ekvationen.

Vi genomförde även studien av datadensitetsreducering på den 2D-Fisher-KPP-ekvationen. Eftersom dess resultat troget speglade de för Burgers (vilket visar att det inte finns något signifikant prestandagap mellan sjätte ordningens OpInf och den adjungerade metoden), utelämnar vi den detaljerade analysen här. Istället fokuserar vi enbart på resultaten från brusstyrningen, vilka visas i Figurerna 4.9, 4.10 och 4.11. På grund av stabilitetsöverväganden i reaktions-diffusionsdynamiken utökade vi i detta fall träningsfönstret till att täcka 75% av den totala simuleringstiden.


Över alla fyra brusnivåer (1%, 5%, 10% och 20%) överträffade den ROM som tränats via den adjungerade metoden konsekvent den bästa OpInf-konfigurationen ('ord6'), både vad gäller trajektorietrogenhet och felmetriker.

I tidsseriejämförelserna av de reducerade tillstånden (Figur 4.10) bekräftar de motsvarande prediktionsfelkurvorna att det adjungerade tillvägagångssättet bibehåller en lägre felevolution över prediktionsintervallet, särskilt vid de högre brusnivåerna där derivatestimeringarna med finita differenser degraderas avsevärt.




Figur 4.10: Prediktionsfel mot tid för varje körning av brusnivå i experimentet med FKPP-ekvationen.


Slutligen visar graferna över relativt fel mot modellens dimension i Figur 4.11 att noggrannheten för den modell som tränats med den adjungerade metoden växer med brusnivå, vilket understryker att beräkningen av den exakta gradienten via denna metod ger tillförlitligare parameteruppdateringar när träningsögonblicksbilderna är korrumpierade. Sammanfattningsvis speglar och förstärker dessa fynd de resultat som erhöles för Burgers; den adjungerade metoden ger en överlägsen robusthet mot mätbrus utan att offra den beräkningsmässiga genomförbarheten.




(a) 1% brusnivå.



(b) 5% brusnivå.



(c) 10% brusnivå.



(d) 20% brusnivå.

Figur 4.11: Relativt fel mot r för varje körning av brusstörning i experimentet med FKPP-ekvationen.

DISKUSSION

I denna avhandling har vi undersökt användningen av träningsmetoder baserade på det adjunkta tillståndet för reducerade ordningsmodeller (ROM) och jämfört detta med standardtillvägagångssättet för OpInf. Våra experiment fokuserade på två huvudsakliga aspekter: inverkan av träningsdatans densitet samt robustheten mot brusiga eller imperfekta data.

Ett centralt fynd är det faktum att en minskning av densiteten hos ögonblicksbildsdata (*snapshots*) hade en minimal effekt på den komparativa prestandan mellan OpInf med högordningens ändliga differenser (FD) och adjunktmetoden. När antalet träningsögonblicksbilder varierades uppvisade både OpInf och de modeller som tränats med adjunktmetoden ett i stort sett likartat beteende. Ingen av metoderna visade någon tydlig fördel i takt med att antalet ögonblicksbilder minskade, och prediktionsfelen förblev jämförbara över alla testade densiteter. Detta tyder på att en måttlig minskning av träningsdata inte eliminerade kritisk information för de system som betraktas i denna avhandling. Märkbara resultat börjar först observeras vid extrema reduktioner, såsom vid 0.2% (endast 20 datapunkter). Denna observation antyder att i frånvaro av brus kräver både adjunktmetoden och högordningens OpInf-metod ett liknande minsta antal ögonblicksbilder för att noggrant identifierar den dominerande dynamiken, vilket möjliggör en säker undermonstring i stora datamängder.

I motsats till datadensiteten avslöjade experimenten med brusiga eller imperfekta data en slående skillnad mellan de båda metoderna. Träningen baserad på det adjunkta tillståndet visade en tydlig fördel i termer av robusthet. Över alla nivåer av tillsatt brus uppnådde de OpInf-ROM som tränats via adjunktmetoden konsistent lägre prediktionsfel och relativa fel än de OpInf-modeller som baserades på ändliga differenser. I takt med att bruset i träningsdata ökade, degenererade prestandan för standard-OpInf mer än för den adjunkta modellen. Detta innebär att under samma brusförhållanden producerade adjunktmetoden mer tillförlitliga prediktioner. En orsak till denna robusthet är att adjunktmetoden justerar modellens parametrar genom att direkt minimera en förlustfunktion som tar hänsyn till

hela banan (*trajectory*). Genom att bakåtpropagera felet genom den tidsliga dynamiken tenderar den att filtrera bort de spuriösa fluktuationer som uppstår till följd av brus i enskilda ögonblicksbilder. I praktiken anpassar optimeringen den reducerade modellen för att passa systemets globala beteende istället för att exakt anpassa sig till varje enskild brusig datapunkt. Å andra sidan löser standard-OpInf ett statistiskt minstakvadratproblem över ögonblicksbildsdatan. Brus i datan kan distordera denna regression, vilket leder till att de infererade koefficienterna blir skeva på grund av bruset och resulterar i sämre prediktioner. Den praktiska implikationen är att adjunktmetoden är mycket väl lämpad för situationer där tillgängliga data är imperfekta, såsom vid mätningar från experiment eller trunkerade simuleringar. I dessa fall innebär dess resiliens att man kan lita på att den reducerade modellen generaliserar bättre, medan OpInf-modellen kan kräva ytterligare åtgärder (till exempel brusfiltrering eller en starkare regularisering) för att undvika överanpassning till bruset. Denna fördel med adjunktträning är särskilt viktig i verkliga applikationer med brusiga eller osäkra data, där det kan vara svårt att erhålla perfekt rena ögonblicksbilder.

Ur datorkostnadssynpunkt medför adjunktmetoden en minimal overhead, eftersom den skalar konstant med antalet parametrar $\hat{\theta} \in \mathbb{R}^d$ (det är endast nödvändigt att lösa en EDO bakåt oberoende av d), till skillnad från primala känslighetsmetoder som skalar linjärt.

Slutligen är det värt att lyfta fram beroendet av en god initial gissning (*initial guess*) för den optimeringsprocess baserad på gradientnedgång (GD) som används i adjunktträningen, vilken i sin tur beror på en optimal lösning från OpInf-metoden. Standard-OpInf är känsligt för stabiliteten och konditioneringen i sitt underliggande regressionsproblem. Tre nyckelfaktorer framträdde som element med betydande inverkan på denna stabilitet:

- (i) För det första är *datans polynomiella struktur* avgörande. OpInf lär sig koefficienterna för en vald uppsättning polynomiella basstermer av det reducerade tillståndet. Om alltför många termer av hög grad inkluderas, eller om särdragen är dåligt skalade, kan regressionsmatrisen bli illakonditionerad.
- (ii) För det andra är *valet av POD-basen $\mathbf{V}_r$* en kritisk faktor. Om denna bas misslyckas med att fånga de viktiga moderna i det fullständiga systemet blir de infererade operatorerna inexakta eller till och med oidentifierbara. Omvänt kan ett val av ett alltför stort värde på r i förhållande till datan amplifiera bruset och göra inferensen illakonditionerad. Därför måste man balansera basens dimension: för få moder missar nyckeldynamik, medan för många kan destabilisera regressionen.
- (iii) För det tredje är *användningen av regularisering* ofta nödvändig för att bekämpa illakonditionering. Utan regularisering kan små singularvärden i regressionen göra att lösningen får överdrivet stora eller ambivalenta koefficienter som överanpassar till bruset. Genom att lägga till en regulariseringsterm (till exempel L^2 , Tikhonov, ...), kan man stabilisera inversionen och säkerställa att de inlärdas operatorerna förblir begränsade. I våra experiment förbättrade införandet av en måttlig mängd regularisering robustheten hos OpInf, på bekostnad av en liten skevhet (*bias*). Denna

kompromiss är i allmänhet värd att göra för att erhålla en stabil modell.

Sammanfattningsvis indikerar våra fynd att både OpInf och metoden baserad på det adjunkta tillståndet kan lära sig effektiva reducerade ordningsmodeller, men deras styrkor skiljer sig åt under olika förhållanden. Att enbart minska ögonblicksbildernas densitet skilde inte de båda metoderna åt avsevärt, eftersom båda fungerade på ett jämförbart sätt med varierande datamängder. Adjunktmetoden visade sig dock vara betydligt mer robust när träningsdata var brusiga eller imperfekta. Sammantaget kan dessa insikter vägleda det praktiska valet av träningsmetoder för ROM. När datakvaliteten är osäker eller när högst möjliga noggrannhet krävs, gör adjunktmetodens resiliens den till en stark kandidat, medan standard-OpInf kan vara tillräckligt när data är rikliga och rena.

SLUTSATSER

I detta arbete har vi utvecklat och analyserat ett ramverk för träning baserat på det adjunkta tillståndet för reducerade ordningsmodeller, formulerat som en integrerad version av standardproblemet för Operator Inference (OpInf). Genom att formulera parameterinlärningen som en optimering för bananpassning (*trajectory matching*) med en exakt beräkning av gradienten, erbjuder adjunktmetoden flera centrala fördelar jämfört med inferens baserad på ändliga differenser. Våra huvudsakliga slutsatser är följande:

- (i) **Robusthet mot imperfekta data.** Adjunktmetoden överträffar konsistent OpInf när träningsögonblicksbilderna (*snapshots*) är korrumperade av brus. Eftersom den minimerar en global förlust över hela tidsintervallet, filtrerar den bort spuriösa fluktuationer och producerar mer tillförlitliga parameteruppskattningar under brusiga eller ofullständiga mätningar.
- (ii) **Kostnadseffektivitet.** Träning baserad på det adjunkta tillståndet innebär en framåtriktad (*forward*) och en bakåtriktad (*backward*) lösning oberoende av antalet parametrar d . För mycket stora modeller eller modeller med hög upplösning är denna konstanta kostnad per iteration mer fördelaktig än för primala känslighetsmetoder, vars kostnad växer linjärt med antalet parametrar.
- (iii) **Flexibilitet och utbyggbarhet.** Det adjunkta ramverket integreras sömlöst med en mängd olika tidsintegrationsscheman och förlustfunktionaler, och kan enkelt inkludera ytterligare fysikaliska villkor eller regulariseringstermer. En sådan modularitet gör det till ett mångsidigt verktyg för att konstruera fysikmedvetna (*physics-aware*) reducerade modeller inom olika dynamiska system.

Utifrån de grunder som presenterats i denna avhandling identifierar vi flera lovande riktningar för framtida studier:

- **Automatisk differentiering för gradientberäkning.** Att ersätta de handanalytiskt härledda adjunkta ekvationerna med en implementering baserad på automatisk differentiering (*autodiff*) skulle kunna förenkla utvecklingen av nya reducerade modeller och minska implementeringsfel.
- **Analys av beräkningskostnadseffektivitet.** Att utföra en jämförande analys (*benchmark*) mellan adjunktmetoden och OpInf genom att utvärdera olika modellstorlekar, antal parametrar och tidshorisonter.
- **Utvidgning till PDE och ytterligare randvillkor.** Att tillämpa adjunktmetoden på andra utmanande system, såsom Eulers eller Navier-Stokes ekvationer, eller på problem med varierande initialvillkor (till exempel periodiska randvillkor) och multifysikalisk koppling, för att ytterligare utvärdera dess generalitet och robusthet.

REFERENSER

- [1] Peter Benner m. fl. "A Survey of Projection-Based Model Reduction Methods for Parametric Dynamical Systems". I: *SIAM Review* 57.4 (2015), s. 483–531. DOI: 10.1137/130932715.
- [2] Alfio Quarteroni m. fl. *Reduced Basis Methods for Partial Differential Equations: An Introduction*. Cham, Switzerland: Springer, 2016.
- [3] Benjamin Peherstorfer m. fl. "Data-driven Operator Inference for Nonintrusive Projection Based Model Reduction". I: *Computer Methods in Applied Mechanics and Engineering* 306 (2016), s. 196–215. DOI: <https://doi.org/10.1016/j.cma.2016.03.025>.
- [4] Omar Ghattas m. fl. "Learning Physics - Based Models from Data: Perspectives from Inverse Problems and Model Reduction". I: *Acta Numerica* 30 (2021). DOI: <https://doi.org/10.1017/S0962492921000064>.
- [5] Ricky T. Q. Chen m. fl. "Neural Ordinary Differential Equations". I: *Advances in Neural Information Processing Systems* 31 (2018). DOI: <https://doi.org/10.48550/arXiv.1806.07366>.
- [6] Harbir Antil m. fl. "A Brief Introduction to PDE-Constrained Optimization". I: *Frontiers in PDE-Constrained Optimization*. Springer, 2018, s. 3–40. DOI: https://doi.org/10.1007/978-1-4939-8636-1_1.
- [7] Andrew M. Bradley. *PDE-Constrained Optimization and the Adjoint Method*. Accessed: 20-Jan-2025. 2024. URL: https://cs.stanford.edu/~ambrad/adjoint_tutorial.pdf.
- [8] Gal Berkooz m. fl. "The Proper Orthogonal Decomposition in the Analysis of Turbulent Flows". I: *Annual review of fluid mechanics* 25.1 (1993), s. 539–575. DOI: <https://doi.org/10.1146/annurev.fl.25.010193.002543>.
- [9] Willcox Research Group. *Operator Inference for Data-Driven Reduced-Order Modeling*. Accessed: 16-Feb-2025. 2025. URL: <https://willcox-research-group.github.io/rom-operator-inference-Python3/source/opinf/intro.html>.

- [10] Boris Kramer m. fl. "Learning Nonlinear Reduced Models from Data with Operator Inference". I: *Annual Review of Fluid Mechanics* 56.1 (2024), s. 521–548. DOI: <https://doi.org/10.1146/annurev-fluid-121021-025220>.
- [11] Clarence W. Rowley m. fl. "Model Reduction for Flow Analysis and Control". I: *Annual Review of Fluid Mechanics* 49.1 (2017), s. 387–417. DOI: <https://doi.org/10.1146/annurev-fluid-010816-060042>.
- [12] C. De Boor. *A Practical Guide to Splines*. New York, NY: Springer-Verlag, 1978.
- [13] J. Frédéric Bonnans m. fl. *Perturbation Analysis of Optimization Problems*. New York, NY: Springer Science & Business Media, 2013.
- [14] Paolo Luchini m. fl. "An Introduction to Adjoint Problems". I: *arXiv preprint arXiv:2404.17304* (2024). DOI: <https://doi.org/10.48550/arXiv.2404.17304>.
- [15] Shane A. McQuarrie m. fl. "Bayesian Learning with Gaussian Processes for Low-Dimensional Representations of Time-Dependent Nonlinear Systems". I: *Physica D: Nonlinear Phenomena* 475 (2025), s. 134572. ISSN: 0167-2789. DOI: <https://doi.org/10.1016/j.physd.2025.134572>.
- [16] Jorge Nocedal m. fl. *Numerical Optimization*. New York, NY: Springer, 1999.
- [17] Daniel Liberzon. *Calculus of Variations and Optimal Control Theory: A Concise Introduction*. Princeton, NJ: Princeton University Press, 2011.
- [18] Sebastian Ruder. *An Overview of Gradient Descent Optimization Algorithms*. Accessed: 16-Feb-2025. 2017. URL: <https://arxiv.org/abs/1609.04747>.
- [19] B. Sengupta m. fl. "Efficient Gradient Computation for Dynamical Models". I: *NeuroImage* 98 (2014), s. 521–527. ISSN: 1053-8119. DOI: <https://doi.org/10.1016/j.neuroimage.2014.04.040>.
- [20] Guillaume Garrigos m. fl. "Handbook of Convergence Theorems for (Stochastic) Gradient Methods". I: *arXiv preprint arXiv:2301.11235* (2023). DOI: <https://doi.org/10.48550/arXiv.2301.11235>.
- [21] Pauli Virtanen m. fl. "SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python". I: *Nature Methods* 17.3 (2020), s. 261–272. DOI: [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2).
- [22] SciPy Developers. 'scipy.integrate.solve_ivp' — *SciPy v1.x Manual*. https://docs.scipy.org/doc/scipy/reference/generated/scipy.integrate.solve_ivp.html. Accessed: 2025-03-09. 2025.
- [23] Tamara G. Kolda m. fl. "Tensor Decompositions and Applications". I: *SIAM Review* 51.3 (2009), s. 455–500. DOI: <https://doi.org/10.1137/07070111X>.

Bilagor

YTTERLIGARE TEORETISKA GRUNDER

A.1 Matrisering av tensorer

I reducerade ordningsmodeller kan den icke-linjära operatören

$$\mathcal{H} : \mathbb{R}^r \times \mathbb{R}^r \rightarrow \mathbb{R}^r$$

som genererar det kvadratiska bidraget

$$[\mathcal{H}(\hat{\mathbf{q}}(t), \hat{\mathbf{q}}(t))]_i = \sum_{j=1}^r \sum_{k=1}^r H_{i,j,k} \hat{q}_j(t) \hat{q}_k(t),$$

tolkas som en tredje ordningens tensor $\mathcal{H} \in \mathbb{R}^{r \times r \times r}$. För att utvärdera denna term effektivt *matriserar* vi tensorn till en matris som verkar på Kronecker-produkten $\hat{\mathbf{q}}(t) \otimes \hat{\mathbf{q}}(t) \in \mathbb{R}^{r^2}$ [23].

Mod-1-utvikningen (matriseringen) $H_{(1)} \in \mathbb{R}^{r \times r^2}$ av $\mathcal{H}$ definieras på ett sådant sätt att

$$H_{(1)} (\hat{\mathbf{q}}(t) \otimes \hat{\mathbf{q}}(t)) = \left[\sum_{j,k} H_{1,j,k} \hat{q}_j \hat{q}_k, \dots, \sum_{j,k} H_{r,j,k} \hat{q}_j \hat{q}_k \right]^\top = \mathcal{H}(\hat{\mathbf{q}}(t), \hat{\mathbf{q}}(t)).$$

Mer konkret, om vi plattar till $\hat{\mathbf{q}}(t)$ till en vektor av längd r^2 genom att stapla dess komponenter i kolumnvis ordning (*column-major order*), så gäller

$$[H_{(1)}]_{i, (j-1)r+k} = H_{i,j,k},$$

och

$$\mathcal{H}(\hat{\mathbf{q}}, \hat{\mathbf{q}}) = H_{(1)} \text{vec}(\hat{\mathbf{q}} \hat{\mathbf{q}}^\top) = \hat{\mathbf{H}}(\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}).$$

Exempel: Burgers ekvation

Betrakta den viskösa 1D Burgers ekvation för det skalära fältet $q(x, t) : [0, 1] \times [0, T] \rightarrow \mathbb{R}$:

$$\frac{\partial q}{\partial t} + q \frac{\partial q}{\partial x} = \nu \frac{\partial^2 q}{\partial x^2}.$$

Efter rumslig diskretisering i n nätpunkter skriver vi

$$\mathbf{q}(t) = [q(x_1, t), q(x_2, t), \dots, q(x_n, t)]^\top \in \mathbb{R}^n.$$

Följaktligen resulterar den konvektiva Burgers-termen i den fullständiga modellen (*FOM*) i

$$\mathbf{N}(\mathbf{q}) = -\mathbf{q} \circ (\mathbf{D}_x \mathbf{q}) \in \mathbb{R}^n,$$

där $\circ$ betecknar Hadamard-produkten (komponentvis multiplikation) och $\mathbf{D}_x \in \mathbb{R}^{n \times n}$ är den ändliga differensmatrisen för operatoren ∂_x . Efter POD-projektion ansätter vi den reducerade formen som

$$\mathbf{q}(t) \approx \Phi \hat{\mathbf{q}}(t), \quad \Phi \in \mathbb{R}^{n \times r}, \quad \hat{\mathbf{q}} \in \mathbb{R}^r.$$

Genom att substituera i $\mathbf{N}$ och projektera på basen erhåller vi

$$\Phi^\top \mathbf{N}(\Phi \hat{\mathbf{q}}) = -\Phi^\top \left[(\Phi \hat{\mathbf{q}}) \circ (\mathbf{D}_x \Phi \hat{\mathbf{q}}) \right].$$

Detta kan uttryckas som en bilinjär form med hjälp av identiteten $(a \circ b)_\ell = \sum_{j,k} \delta_{\ell j} a_j \delta_{\ell k} b_k$.

Utifrån denna kan det visas att

$$[\Phi^\top (\Phi \hat{\mathbf{q}} \circ D_x \Phi \hat{\mathbf{q}})]_i = \sum_{j=1}^r \sum_{k=1}^r \underbrace{\sum_{\ell=1}^n \Phi_{\ell,i} \Phi_{\ell,j} [D_x \Phi]_{\ell,k}}_{\mathcal{H}_{i,j,k}} \hat{q}_j \hat{q}_k.$$

Koefficienterna

$$\mathcal{H}_{i,j,k} = - \sum_{\ell=1}^n \Phi_{\ell,i} \Phi_{\ell,j} [D_x \Phi]_{\ell,k}, \quad i, j, k = 1, \dots, r,$$

definierar således en tredje ordningens tensor $\mathcal{H} \in \mathbb{R}^{r \times r \times r}$. Mod-1-utvikningen (matriseringen) ger den motsvarande matrisen $H_{(1)} \in \mathbb{R}^{r \times r^2}$ med komponenterna

$$[H_{(1)}]_{i, (j-1)r+k} = \mathcal{H}_{i,j,k}, \quad 1 \leq i, j, k \leq r,$$

så att

$$\Phi^\top \mathbf{N}(\Phi \hat{\mathbf{q}}) = H_{(1)} (\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}) = \hat{\mathbf{H}} (\hat{\mathbf{q}} \otimes \hat{\mathbf{q}}).$$

Här kodar $\hat{\mathbf{H}} \in \mathbb{R}^{r \times r^2}$ de projekterade icke-linjära interaktionerna. Denna matriserade form möjliggör en effektiv beräkning av $\hat{\mathbf{H}}$ under operatorinferensen, samtidigt som den kvadra-

tiska icke-linjära strukturen bevaras.

A.2 Kubisk splineinterpolation

Kubiska splines är styckvisa polynomiella funktioner som garanterar släthet och kontinuitet upp till den andra derivatan i datapunkterna. Givet N punkter $\{(t_i, u_i)\}_{i=1}^N$, definieras den kubiska splinen $S(t)$ styckvis enligt:

$$S(t) = S_i(t), \quad t \in [t_i, t_{i+1}]$$

där varje $S_i(t)$ är ett kubiskt polynom:

$$S_i(t) = a_i + b_i(t - t_i) + c_i(t - t_i)^2 + d_i(t - t_i)^3.$$

Koefficienterna a_i, b_i, c_i, d_i bestäms genom följande villkor:

- Interpolationsvillkor: $S_i(t_i) = u_i$ och $S_i(t_{i+1}) = u_{i+1}$,
- Kontinuitet för den första och andra derivatan i de interna noderna:

$$S'_i(t_{i+1}) = S'_{i+1}(t_{i+1}), \quad S''_i(t_{i+1}) = S''_{i+1}(t_{i+1}),$$

- Randvillkor: antingen en *naturlig* spline ($S''_1(t_1) = 0$ och $S''_{N-1}(t_N) = 0$) eller en *fastlåst* (*clamped*) spline (föreskrivna förstaderivator vid domänens ändpunkter).

Kubiska splines säkerställer släthet och ger en naturlig interpolation som undviker de oscillerande fenomen som är typiska för polynominterpolation av hög grad [12]. De släthets- och kontinuitetsvillkor som påtvingas av kubiska splines —specifikt existensen av kontinuerliga första- och andraderivator— är essentiella för tillämpningen av adjunktmetoden (Avsnitt 3.2). Adjunktmetoden kräver att den interpolerade banan $\hat{\mathbf{q}}(t)$ är minst av klass $\mathcal{C}^1$ för att säkerställa att de adjunkta ekvationerna är välställda samt att gradienten beräknas noggrant. Kubiska splines uppfyller detta krav, eftersom deras $\mathcal{C}^2$ -kontinuitet garanterar att $\hat{\mathbf{q}}(t)$ är två gånger deriverbar över hela domänen $\mathcal{T}$. Detta förhindrar numeriska instabiliteter som annars skulle kunna uppstå på grund av diskontinuerliga derivator när det adjunkta systemet löses bakåt i tiden. Genom att påtvinga kontinuitet hos derivatorna i noderna bevarar kubiska splines den struktur som krävs för att tillämpa kedjeregeln i (3.6), vilket möjliggör en effektiv gradientbaserad optimering av förlustfunktionalen i kontinuerlig tid (3.1).

PYTHON-KOD

Burgers ekvation

Listing B.1: *Lösning av Burgers ekvation i 1D. Generering av snapshots för data (Q)*

```

1 import numpy as np
2 from scipy.sparse import diags
3 from scipy.sparse.linalg import spsolve
4
5 # Grid and time parameters
6 M = 9999 # Number of time steps
7 T = 1.0 # Final time
8 dt = T / M # Time step size
9
10 # N = 998 # Number of spatial grid points
11 N = 2**7 # Number of spatial grid points
12 L = 1.0 # Domain length
13 dx = L / (N + 1) # Spatial step size (excluding boundary points)
14
15 x = np.linspace(0, L, N+2) # Includes boundary points
16 t = np.linspace(0, T, M+1)
17
18 # Diffusivity (viscosity)
19 nu = 0.01
20
21 # Initial condition  $q(x,0) = \sin(x)$  (excluding boundaries)
22 q0 = np.sin(2*np.pi * x[1:-1])
23
24 # Solution matrix initialization (excluding boundaries)
25 Q = np.zeros((N, M+1))
26 Q[:, 0] = q0
27
28 # Finite Difference Matrix (Diffusion Term)
29 off_diag = np.full(N-1, 1 / dx**2)
30 main_diag = np.full(N, -2 / dx**2)

```

```

31 Tdx = diags([off_diag, main_diag, off_diag], [-1, 0, 1], shape=(N, N)).
32     tocsr()
33
34 # Function to compute next time step using implicit diffusion
35 def viscous_burgers(qold, nu, dt, dx):
36     n = len(qold)
37     dx2 = dx**2
38
39     # Lax-Wendroff for nonlinear convection term
40     qjpone = np.roll(qold, -1)
41     qjmone = np.roll(qold, 1)
42
43     LW = qold - (dt / (2 * dx)) * qold * (qjpone - qjmone) + \
44         (dt**2 / (2 * dx2)) * qold * (0.5 * (qjpone - qjmone)**2 + \
45         qold * (qjpone - 2 * qold + qjmone))
46
47     # Apply Dirichlet BC: q(0,t) = q(1,t) = 0
48     LW[0] = 0
49     LW[-1] = 0
50
51     # Implicit diffusion term
52     A = np.eye(n) - nu * (dt / 2) * Tdx.toarray()
53     rhs = LW + nu * (dt / 2) * (Tdx @ qold)
54
55     # Solve linear system
56     qnew = spsolve(A, rhs)
57
58     # Enforce boundary conditions
59     qnew[0] = 0
60     qnew[-1] = 0
61
62     return qnew
63
64 # Time stepping
65 qold = q0.copy()
66 for i in range(M):
67     qnew = viscous_burgers(qold, nu, dt, dx)
68     Q[:, i+1] = qnew
69     qold = qnew
70
71 # Extend solution to include boundary points (q=0 at x=0 and x=1)
72 Qfom = np.zeros((N+2, M+1))
73 Qfom[1:-1, :] = Q # Fill interior points

```


Fisher-KPP-ekvationen

Listing B.2: Lösning av den tvådimensionella Fisher-KPP-ekvationen. Generering av (Q)

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.sparse import diags, kron, eye, csc_matrix
4 from scipy.sparse.linalg import spsolve
5
6 # Parameters
7 Lx = 10.0          # Domain length in x-direction
8 Ly = 10.0          # Domain length in y-direction
9 Nx = 100           # Number of spatial points in x-direction
10 Ny = 100           # Number of spatial points in y-direction
11 dx = Lx / (Nx - 1) # Spatial step in x
12 dy = Ly / (Ny - 1) # Spatial step in y
13 D = 0.1            # Diffusion coefficient
14 r = 1.0            # Growth rate
15 dt = 0.005         # Time step
16 T = 5.0            # Total simulation time
17 Nt = int(T / dt)   # Number of time steps
18
19 # Spatial grids
20 x = np.linspace(0, Lx, Nx)
21 y = np.linspace(0, Ly, Ny)
22 X, Y = np.meshgrid(x, y)
23
24 # Initial condition: 2D Gaussian at the center
25 u0 = np.exp(-10 * ((X - Lx/2)**2 + (Y - Ly/2)**2))
26 u = u0.flatten()   # Flatten to 1D vector
27
28 # Function to construct 1D Laplacian matrix with Neumann BCs
29 def construct_1d_laplacian(N, d):
30     main_diag = -2 * np.ones(N) / d**2
31     super_diag = np.ones(N-1) / d**2
32     sub_diag = np.ones(N-1) / d**2
33     # Neumann BC adjustments
34     super_diag[0] = 2 / d**2
35     sub_diag[-1] = 2 / d**2
36     return diags([sub_diag, main_diag, super_diag], [-1, 0, 1], format="csc")
37
38 # Construct 1D Laplacians
39 Lx = construct_1d_laplacian(Nx, dx)
40 Ly = construct_1d_laplacian(Ny, dy)
41
42 # Construct 2D Laplacian using Kronecker products
43 Ix = eye(Nx, format="csc")
44 Iy = eye(Ny, format="csc")
45 L = kron(Iy, Lx) + kron(Ly, Ix)
46

```

```

47 # Crank-Nicolson matrix
48 alpha = D * dt / 2
49 A = eye(Nx * Ny) - alpha * L
50 A = A.tocsc()
51
52 # Store solutions at certain time steps
53 snapshot_interval = 1 # Desired number of interval snapshot to store
54 snapshots = []
55
56 # Time stepping
57 for tt in range(1, Nt+1):
58     u_prev = u.copy()
59     reaction = r * u_prev * (1 - u_prev)
60     b = u_prev + dt * reaction + alpha * L.dot(u_prev)
61     u = spsolve(A, b)
62
63     if tt % snapshot_interval == 0:
64         snapshots.append(u.reshape(Ny, Nx))
65
66 # Convert snapshots to numpy array
67 Qfom = np.array(snapshots)

```

Adjunktmetoden

Listing B.3: *Algorithm för adjunktmetoden.*

```

1 import numpy as np
2 import opinf
3 from scipy.integrate import cumulative_trapezoid
4
5 ##### OpInf #####
6 #####
7
8 opinf.utils.mpl_config()
9
10 # Parameters
11 r = 10
12 k_samples = 1000 # number of samples (snapshot data)
13 T = 1.0
14
15 # Snapshot data Q = [q(t_0) q(t_1) ... q(t_k)], size=(r,k)
16 Q = np.load("burgers_snapshots.npy")
17 t = np.load("burgers_time.npy") # t_0 = 0, ..., t_k = 1
18 x = np.load("burgers_space.npy")
19
20 dt = t[1] - t[0]
21
22 # Initialize orthonormal basis V
23 Vr = opinf.basis.PODBasis(cumulative_energy=0.999)

```

```

24 #Vr = opinf.basis.PODBasis(num_vectors=r)
25 Vr.fit(Q)
26 print(Vr)
27
28 # Compressed state snapshots Q_ by projecting onto the reduced space
   defined by Vr
29 Q_ = Vr.compress(Q)
30
31 # Estimate time derivatives using 6-thorder finite differences.
32 ddt_estimator = opinf.ddt.UniformFiniteDifferencer(t, "ord6")
33 Qdot_ = ddt_estimator.estimate(Q_)[1]
34
35 # Build the quadratic continuous model and fit it.
36 model = opinf.models.ContinuousModel(operators=["A", "H"])
37 model.fit(states=Q_, ddts=Qdot_)
38 A_opinf = model.operators[0].entries
39 H_opinf = model.operators[1].entries
40
41 # Expanded H: size (r, r^2)
42 H_opinf = opinf.operators.QuadraticOperator.expand_entries(H_opinf)
43
44 # Flatten A and H to build initial guess for theta.
45 # Start from the OpInf solution.
46 theta = np.concatenate([A_opinf.ravel(), H_opinf.ravel()])
47
48 ##### RHS #####
49 #####
50
51 # Integral of q(tau) from 0 to t_k for each t_k.
52 Q_int = np.zeros_like(Q_)
53 for i in range(r):
54     Q_int[i, :] = cumulative_trapezoid(Q_[i, :], t, initial=0)
55
56 # Quantity q(tau) q(tau) for each tau.
57 Q2_ = np.zeros((r**2, k_samples))
58 for k in range(k_samples):
59     q_k = Q[:, k]
60     Q2_[:, k] = np.kron(q_k, q_k)
61
62 # Integral of q(tau) q(tau) from 0 to t_k.
63 Q2_int = np.zeros_like(Q2_)
64 for i in range(r**2):
65     Q2_int[i, :] = cumulative_trapezoid(Q2_[i, :], t, initial=0)
66
67 ##### GD Parameters #####
68 #####
69
70 max_iter = 1000
71 epsilon = 1e-8 # stopping threshold for gradient norm
72
73 # Armijo parameters:

```

```

74 eta = 1e-3          # initial learning rate
75 alpha = 1e-4
76 beta = 0.5
77 d = r**2 + r**3
78
79 ##### GD Loop #####
80 #####
81
82 for j in range(max_iter):
83     A = theta[:r**2].reshape(r, r)
84     H = theta[r**2:].reshape(r, r**2)
85     q0 = Q[:, 0]
86
87     # Compute predicted states: tilde_Q = q0 + A @ Q_int + H @ Q2_int.
88     tilde_Q = q0[:, np.newaxis] + A @ Q_int + H @ Q2_int
89
90     # Loss computation: mean squared error.
91     loss = np.mean(np.sum((Q_ - tilde_Q)**2, axis=0))
92     print(f"Iteration {j}, Loss: {loss:.6f}")
93
94     # Solve adjoint ODE backwards using implicit Euler.
95     lambda_values = np.zeros((r, k_samples))
96     lambda_values[:, -1] = 0.0 # Terminal condition: (T)=0
97
98     for k in reversed(range(k_samples - 1)):
99         q_k = Q[:, k]
100         tilde_q_k = tilde_Q[:, k]
101         error_k = q_k - tilde_q_k
102
103         # Compute M(q_k)
104         H_3d = H.reshape(r, r, r)
105         M_k = np.einsum("ijk,j->ki", H_3d, q_k)
106
107         # Backward Euler step.
108         matrix = np.eye(r) + dt * (A.T + 2 * M_k)
109         rhs = lambda_values[:, k+1] - 2 * dt * error_k
110         lambda_values[:, k] = np.linalg.solve(matrix, rhs)
111
112     # Gradient computation.
113     grad_A = np.zeros(r**2)
114     grad_H = np.zeros(r**3)
115
116     for k in range(k_samples):
117         lambda_k = lambda_values[:, k]
118         q_k = Q[:, k]
119
120         # Gradient parts for A.
121         outer_A = np.outer(lambda_k, q_k).flatten()
122         grad_A += outer_A * dt
123
124         # Gradient parts for H.

```

```

125     q_outer = np.outer(q_k, q_k).flatten()
126     outer_H = np.outer(lambda_k, q_outer).flatten()
127     grad_H += outer_H * dt
128
129     gradient = np.concatenate([grad_A, grad_H])
130     grad_norm = np.linalg.norm(gradient)
131
132     if grad_norm < epsilon:
133         print("Gradient norm below tolerance; stopping descent.")
134         break
135
136     # Armijo backtracking line search
137     eta_current = eta * 1.05 # Initial trial step size
138     ls_success = False
139     for _ in range(50): # Max line search iterations
140         theta_new = theta - eta_current * gradient
141         A = theta_new[:r**2].reshape(r, r)
142         H = theta_new[r**2:].reshape(r, r**2)
143         tilde_Q = q0[:, np.newaxis] + A @ Q_int + H @ Q2_int
144         loss_new = np.mean(np.sum((Q_ - tilde_Q)**2, axis=0))
145
146         if loss_new <= loss - alpha * eta_current * (grad_norm ** 2):
147             eta = eta_current
148             theta = theta_new
149             ls_success = True
150             break
151         else:
152             eta_current *= beta
153
154     if not ls_success:
155         theta = theta - eta * gradient # Fallback to previous eta
156         A = theta[:r**2].reshape(r, r)
157         H = theta[r**2:].reshape(r, r**2)
158         tilde_Q = q0[:, np.newaxis] + A @ Q_int + H @ Q2_int
159         loss_new = np.mean(np.sum((Q_ - tilde_Q)**2, axis=0))
160         if loss_new > loss:
161             eta *= beta # Force reduce eta if line search failed
162
163
164     # Detach optimal A and H from theta.
165     A_opt = theta[:r**2].reshape(r, r)
166     H_opt = theta[r**2:].reshape(r, r**2)

```


Master's Theses in Mathematical Sciences 2025:E20
ISSN 1404-6342
LUNFNA-3045-2025
Numerisk analys
Matematikcentrum
Lunds universitet
Box 118, 221 00 Lund
<http://www.maths.lu.se/>